# DDIM 论文阅读笔记

*Denoising Diffusion Implicit Models*

Jiaming Song, Chenlin Meng, Stefano Ermon ICLR 2021

阅读笔记整理

2026 年 3 月 1 日

## §1 论文基本信息

| | |
|---|---|
| 发表会议 | ICLR 2021 |
| 作者单位 | Stanford University |
| 关键词 | 去噪扩散隐式模型 (DDIM)、非马尔可夫过程、确定性采样、加速生成、隐空间插值 |
| 论文链接 | `arXiv:2010.02502` |
| 前置工作 | DDPM (Ho et al., NeurIPS 2020) |

**核心摘要**

本文提出了**去噪扩散隐式模型（DDIM）**，解决了 DDPM 采样速度极慢的核心瓶颈。关键洞察在于：DDPM 的训练目标仅依赖于前向过程的**边缘分布** $q(\mathbf{x}_t|\mathbf{x}_0)$，而非联合分布，因此存在一大类与 DDPM 目标等价、但对应**非马尔可夫**前向过程的生成模型。通过令随机性参数 $\sigma_t \to 0$，可以得到一个完全确定性的生成过程（DDIM），使得**同一预训练模型**无需重新训练即可以 10×–50× 的速度生成高质量样本，同时具备语义意义的隐空间插值和精确图像重建能力。

# §2 研究背景与动机

## 2.1 DDPM 的核心缺陷：采样极慢

DDPM 虽然实现了高质量图像生成，但其采样过程是一个需要完整运行 $T = 1000$ 步的马尔可夫链，每步都需要神经网络前向传播，导致采样极为耗时：

| 模型 | 生成 50k 张 $32 \times 32$ 图像 | 生成 50k 张 $256 \times 256$ 图像 |
|---|---|---|
| GAN | $< 1$ 分钟 | 数分钟 |
| DDPM ($T = 1000$) | $\approx 20$ 小时 | $\approx 1000$ 小时 |
| **DDIM** ($S = 50$) | $\approx 1$ 小时 | 大幅缩短 |

以上数据均基于单块 Nvidia 2080 Ti GPU。

## 2.2 关键观察：训练目标与联合分布无关

DDPM 的简化训练目标 $L_{\text{simple}}$（等价于 $L_1$）可以写为：

$$L_1(\theta) = \sum_{t=1}^{T} \mathbb{E}_{\mathbf{x}_0,\boldsymbol{\epsilon}} \left[ \left\| \boldsymbol{\epsilon}_\theta^{(t)} \left( \sqrt{\bar{\alpha}_t}\, \mathbf{x}_0 + \sqrt{1-\bar{\alpha}_t}\, \boldsymbol{\epsilon} \right) - \boldsymbol{\epsilon} \right\|^2 \right] \tag{1}$$

**核心洞察**

$L_1$ **只依赖边缘分布** $q(\mathbf{x}_t|\mathbf{x}_0) = \mathcal{N}(\sqrt{\bar{\alpha}_t}\mathbf{x}_0, (1-\bar{\alpha}_t)\mathbf{I})$，**不依赖联合分布** $q(\mathbf{x}_{1:T}|\mathbf{x}_0)$！这意味着：满足相同边缘分布约束的**任意推断过程**（包括非马尔可夫过程）都共享同一个训练目标，因此可以使用**同一套预训练权重**来驱动不同的生成过程。

## 2.3 论文的核心贡献

1. **理论推广**：将 DDPM 的马尔可夫前向过程推广到一大类**非马尔可夫前向过程**族，证明其变分目标与 DDPM 共享代理目标函数。
2. **确定性采样器**：提出 $\sigma_t = 0$ 特例——DDIM，将随机采样变为确定性 ODE 求解，实现 10×–50× 加速。
3. **一致性**：DDIM 的确定性使得相同初始潜变量 $\mathbf{x}_T$ 在不同采样轨迹下产生高度一致的高层特征。
4. **隐空间操控**：支持在 $\mathbf{x}_T$ 空间进行语义插值和图像重建，DDPM 由于随机性无法实现。

# §3 方法详解：非马尔可夫前向过程

## 3.1 推断过程的推广

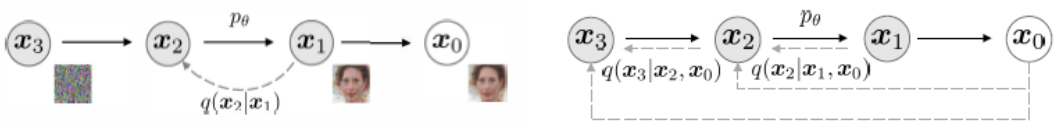


Figure 1: Graphical models for diffusion (left) and non-Markovian (right) inference models.

DDIM 定义了一族由参数 $\boldsymbol{\sigma} \in \mathbb{R}^T_{\geq 0}$ 索引的推断分布 $\mathcal{Q}$：

**非马尔可夫推断过程定义**

$$q_\sigma(\mathbf{x}_{1:T}|\mathbf{x}_0) := q_\sigma(\mathbf{x}_T|\mathbf{x}_0) \prod_{t=2}^{T} q_\sigma(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0) \tag{2}$$

$$q_\sigma(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0) := \mathcal{N}\left(\sqrt{\bar{\alpha}_{t-1}}\,\mathbf{x}_0 + \sqrt{1-\bar{\alpha}_{t-1}-\sigma_t^2} \cdot \frac{\mathbf{x}_t - \sqrt{\bar{\alpha}_t}\,\mathbf{x}_0}{\sqrt{1-\bar{\alpha}_t}},\ \sigma_t^2\mathbf{I}\right) \tag{3}$$

其中 $q_\sigma(\mathbf{x}_T|\mathbf{x}_0) = \mathcal{N}(\sqrt{\bar{\alpha}_T}\mathbf{x}_0, (1-\bar{\alpha}_T)\mathbf{I})$。

**符号说明：**

- $q_\sigma(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0)$：条件于**原始数据** $\mathbf{x}_0$ 和当前状态 $\mathbf{x}_t$ 的反向转移。由于依赖 $\mathbf{x}_0$，这是一个**非马尔可夫**过程（不仅仅依赖 $\mathbf{x}_{t-1}$）。
- $\sqrt{\bar{\alpha}_{t-1}}\,\mathbf{x}_0$：均值的”信号锚点”——将预测逐步拉向真实 $\mathbf{x}_0$。
- $\sqrt{1-\bar{\alpha}_{t-1}-\sigma_t^2} \cdot \frac{\mathbf{x}_t - \sqrt{\bar{\alpha}_t}\mathbf{x}_0}{\sqrt{1-\bar{\alpha}_t}}$：”指向 $\mathbf{x}_t$ 的方向分量”。
- $\sigma_t^2\mathbf{I}$：每步注入的随机噪声，$\sigma_t = 0$ 时退化为完全确定性过程。

### 3.1.1 边缘分布保持定理（Lemma 1）

尽管联合分布 $q_\sigma(\mathbf{x}_{1:T}|\mathbf{x}_0)$ 是非马尔可夫的，但其边缘分布与 DDPM 完全一致：

对所有 $t$，有：

$$q_\sigma(\mathbf{x}_t|\mathbf{x}_0) = \mathcal{N}\left(\sqrt{\bar{\alpha}_t}\,\mathbf{x}_0,\ (1-\bar{\alpha}_t)\mathbf{I}\right) \tag{4}$$

此性质保证了训练目标的等价性（见定理 1）。

### 3.1.2 与 DDPM 马尔可夫过程的关系

**马尔可夫 vs 非马尔可夫前向过程**

- **DDPM（马尔可夫，$\sigma_t = \sqrt{\frac{(1-\bar{\alpha}_{t-1})(1-\bar{\alpha}_t/\bar{\alpha}_{t-1})}{1-\bar{\alpha}_t}}$）**：$q(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0)$ 等于 DDPM 的正向后验 $\tilde{\boldsymbol{\mu}}_t$，前向过程是马尔可夫的。
- **DDIM（$\sigma_t = 0$ 对所有 $t$）**：$\mathbf{x}_{t-1}$ 给定 $\mathbf{x}_t$ 和 $\mathbf{x}_0$ 是**确定性**的（除 $t=1$ 外），整个生成过程无随机性。
- **中间态（$0 < \sigma_t <$ DDPM 值）**：插值于确定性和随机性之间，通过超参数 $\eta$ 控制（$\eta = 0$ 为 DDIM，$\eta = 1$ 为 DDPM）。

## 3.2 核心定理：等价训练目标（Theorem 1）

对所有 $\boldsymbol{\sigma} > 0$，存在权重向量 $\gamma \in \mathbb{R}^T_{>0}$ 和常数 $C$，使得：

$$J_\sigma(\theta) = L_\gamma(\theta) + C \tag{5}$$

其中 $J_\sigma$ 是对应非马尔可夫过程 $q_\sigma$ 的变分目标。
**推论**：当参数 $\theta^{(t)}$ 在不同时间步不共享时，$L_1$（即 DDPM 目标）是 $J_\sigma$ 的代理目标——**无需重新训练，直接用预训练 DDPM 权重驱动 DDIM**。

## 3.3 DDIM 采样更新公式

**DDIM 统一采样更新公式**

$$\mathbf{x}_{t-1} = \underbrace{\sqrt{\bar{\alpha}_{t-1}} \cdot \frac{\mathbf{x}_t - \sqrt{1-\bar{\alpha}_t}\,\boldsymbol{\epsilon}_\theta^{(t)}(\mathbf{x}_t)}{\sqrt{\bar{\alpha}_t}}}_{\text{"预测的}\mathbf{x}_0\text{"}} + \underbrace{\sqrt{1-\bar{\alpha}_{t-1}-\sigma_t^2} \cdot \boldsymbol{\epsilon}_\theta^{(t)}(\mathbf{x}_t)}_{\text{"指向}\mathbf{x}_t\text{ 的方向"}} + \underbrace{\sigma_t \boldsymbol{\epsilon}_t}_{\text{随机噪声}} \tag{6}$$

其中 $\boldsymbol{\epsilon}_t \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$，$\bar{\alpha}_0 := 1$。

**三项的物理意义：**

- **第一项（预测的 $\mathbf{x}_0$）**：利用网络预测的噪声 $\boldsymbol{\epsilon}_\theta^{(t)}(\mathbf{x}_t)$，通过重参数化公式反解出估计的原始图像：
$$f_\theta^{(t)}(\mathbf{x}_t) := \frac{\mathbf{x}_t - \sqrt{1-\bar{\alpha}_t}\,\boldsymbol{\epsilon}_\theta^{(t)}(\mathbf{x}_t)}{\sqrt{\bar{\alpha}_t}}$$
再将其按 $\bar{\alpha}_{t-1}$ 缩放，确保 $\mathbf{x}_{t-1}$ 中的信号部分与目标一致。
- **第二项（方向分量）**：从估计的 $\mathbf{x}_0$ 到 $\mathbf{x}_t$ 的" 残差方向"，乘以系数 $\sqrt{1-\bar{\alpha}_{t-1}-\sigma_t^2}$ 以满足方差约束。
- **第三项（随机噪声）**：额外注入的随机性。当 $\sigma_t = 0$ 时此项消失，整个过程变为确定性映射。

### 3.3.1 特殊情况：DDIM（$\sigma_t = 0$）

当所有步骤 $\sigma_t = 0$ 时，采样更新简化为：

**DDIM 确定性采样（$\sigma_t = 0$）**

$$\mathbf{x}_{t-1} = \sqrt{\bar{\alpha}_{t-1}}\, f_\theta^{(t)}(\mathbf{x}_t) + \sqrt{1-\bar{\alpha}_{t-1}} \cdot \boldsymbol{\epsilon}_\theta^{(t)}(\mathbf{x}_t) \tag{7}$$

此时整个生成轨迹 $\mathbf{x}_T \to \mathbf{x}_{T-1} \to \cdots \to \mathbf{x}_0$ 是**完全确定的函数**，$\mathbf{x}_0 = f(\mathbf{x}_T;\theta)$。

## 3.4 加速采样：跳步子序列

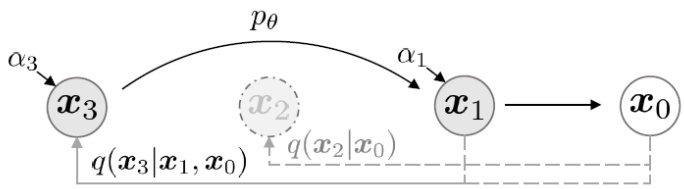


Figure 2: Graphical model for accelerated generation, where $\tau = [1, 3]$.

DDIM 的一个重要功能是可以只在 $[1,\ldots,T]$ 的**子序列**上采样，无需逐步迭代全部 $T$ 步：

**加速采样的关键思想**

设 $\tau = [\tau_1, \tau_2, \ldots, \tau_S]$ 是 $\{1,\ldots,T\}$ 的一个长度为 $S \ll T$ 的递增子序列，则：

- 定义在子序列 $\{\mathbf{x}_{\tau_i}\}_{i=1}^S$ 上的推断过程，使其**边缘分布**仍满足 $q(\mathbf{x}_{\tau_i}|\mathbf{x}_0) =$

$\mathcal{N}(\sqrt{\bar{\alpha}_{\tau_i}}\mathbf{x}_0, (1-\bar{\alpha}_{\tau_i})\mathbf{I})$。

- 由于训练目标 $L_1$ 不依赖具体的前向过程结构，**无需重新训练**，直接用原模型即可。
- 采样步数从 $T = 1000$ 降至 $S = 10 \sim 100$，实现 **10×–100× 加速**。

子序列选取策略：CIFAR10 使用二次方间隔（$\tau_i = \lfloor ci^2 \rfloor$）；大分辨率数据集使用线性间隔（$\tau_i = \lfloor ci \rfloor$）。

对应的更新公式（将 $t \to \tau_i$，$t-1 \to \tau_{i-1}$）：

$$\mathbf{x}_{\tau_{i-1}} = \sqrt{\bar{\alpha}_{\tau_{i-1}}} \cdot f_\theta^{(\tau_i)}(\mathbf{x}_{\tau_i}) + \sqrt{1 - \bar{\alpha}_{\tau_{i-1}} - \sigma_{\tau_i}^2(\eta)} \cdot \boldsymbol{\epsilon}_\theta^{(\tau_i)}(\mathbf{x}_{\tau_i}) + \sigma_{\tau_i}(\eta)\,\boldsymbol{\epsilon} \tag{8}$$

其中随机性参数由超参数 $\eta \in [0, 1]$ 控制：

$$\sigma_{\tau_i}(\eta) = \eta \sqrt{\frac{1-\bar{\alpha}_{\tau_{i-1}}}{1-\bar{\alpha}_{\tau_i}}} \cdot \sqrt{1 - \frac{\bar{\alpha}_{\tau_i}}{\bar{\alpha}_{\tau_{i-1}}}} \tag{9}$$

## 3.5 与 Neural ODE 的联系

DDIM 的更新公式可以改写为类似 Euler 积分的形式：

**DDIM 的 ODE 解释**

定义 $\bar{\mathbf{x}}(t) = \mathbf{x}(t)/\sqrt{\bar{\alpha}(t)}$ 和 $\sigma(t) = \sqrt{(1-\bar{\alpha}(t))/\bar{\alpha}(t)}$，则 DDIM 迭代等价于求解 ODE：

$$\mathrm{d}\bar{\mathbf{x}}(t) = \boldsymbol{\epsilon}_\theta^{(t)}\left(\frac{\bar{\mathbf{x}}(t)}{\sqrt{\sigma^2(t)+1}}\right)\mathrm{d}\sigma(t) \tag{10}$$

初始条件为 $\mathbf{x}(T) \sim \mathcal{N}(\mathbf{0}, \sigma^2(T)\mathbf{I})$（$\bar{\alpha}(T) \approx 0$）。

这一 ODE 视角带来三大洞察：

- **可逆性**：ODE 可以**双向积分**——从 $\mathbf{x}_0$ 积分至 $\mathbf{x}_T$（编码），再从 $\mathbf{x}_T$ 积分回 $\mathbf{x}_0$（解码），实现几乎无损的图像重建。
- **加速方向**：可以使用更高阶的 ODE 求解器（Adams-Bashforth 等）进一步提升精度/效率，为后续 DPM-Solver 等工作奠定基础。
- **理论等价**：该 ODE 等价于 Song et al. (2020) 中”方差爆炸 SDE（VE-SDE）”对应的概率流 ODE。

# §4 完整采样算法

**Algorithm 1** DDIM 采样过程（统一形式，通过 $\eta$ 控制随机性）

**初始化**：选取子序列 $\tau = [\tau_1, \ldots, \tau_S]$，设置超参数 $\eta \in [0, 1]$
从先验采样：$\mathbf{x}_{\tau_S} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$
**for** $i = S, S-1, \ldots, 1$ **do**
  **预测噪声**：$\hat{\boldsymbol{\epsilon}} = \boldsymbol{\epsilon}_\theta^{(\tau_i)}(\mathbf{x}_{\tau_i})$
  **估计** $\mathbf{x}_0$：$\hat{\mathbf{x}}_0 = \left(\mathbf{x}_{\tau_i} - \sqrt{1-\bar{\alpha}_{\tau_i}}\,\hat{\boldsymbol{\epsilon}}\right) / \sqrt{\bar{\alpha}_{\tau_i}}$
  **计算方差**：$\sigma = \eta \sqrt{\frac{1-\bar{\alpha}_{\tau_{i-1}}}{1-\bar{\alpha}_{\tau_i}} \left(1 - \frac{\bar{\alpha}_{\tau_i}}{\bar{\alpha}_{\tau_{i-1}}}\right)}$
  采样随机噪声：若 $\eta > 0$ 则 $\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$，否则 $\boldsymbol{\epsilon} = \mathbf{0}$
  **更新**：
  $\mathbf{x}_{\tau_{i-1}} = \sqrt{\bar{\alpha}_{\tau_{i-1}}}\,\hat{\mathbf{x}}_0 + \sqrt{1-\bar{\alpha}_{\tau_{i-1}} - \sigma^2}\,\hat{\boldsymbol{\epsilon}} + \sigma\,\boldsymbol{\epsilon}$
**end for**
**return** $\mathbf{x}_0$

**Algorithm 2** DDIM 编码过程（图像到隐变量，$\eta = 0$）

**输入**：原始图像 $\mathbf{x}_0$，子序列 $\tau$
**for** $i = 1, 2, \ldots, S$ **do**
  预测噪声：$\hat{\boldsymbol{\epsilon}} = \boldsymbol{\epsilon}_\theta^{(\tau_i)}(\mathbf{x}_{\tau_{i-1}})$
  估计 $\mathbf{x}_0$：$\hat{\mathbf{x}}_0 = \left(\mathbf{x}_{\tau_{i-1}} - \sqrt{1-\bar{\alpha}_{\tau_{i-1}}}\,\hat{\boldsymbol{\epsilon}}\right) / \sqrt{\bar{\alpha}_{\tau_{i-1}}}$
  前向更新：$\mathbf{x}_{\tau_i} = \sqrt{\bar{\alpha}_{\tau_i}}\,\hat{\mathbf{x}}_0 + \sqrt{1-\bar{\alpha}_{\tau_i}}\,\hat{\boldsymbol{\epsilon}}$
**end for**
**return** $\mathbf{x}_{\tau_S}$（编码后的隐变量 $\mathbf{x}_T$）

# §5 DDIM 的独特优势

## 5.1 采样一致性（Consistency）

由于 DDIM 的生成过程是确定性函数 $\mathbf{x}_0 = G(\mathbf{x}_T)$，相同的初始潜变量 $\mathbf{x}_T$ 在不同采样轨迹（不同步数 $S$）下生成的图像具有高度相似的**高层语义特征**：

- 仅用 20 步生成的图像与 1000 步生成的图像，在姿态、整体结构、颜色调性等方面高度一致。
- 差异主要体现在**精细纹理细节**上——步数越多，细节越丰富。

- 这说明 $\mathbf{x}_T$ 是图像**语义内容的有效编码**，图像细节则由迭代步骤数决定。

**注意**

DDPM 由于随机性，相同 $\mathbf{x}_T$ 在不同步数下会产生完全不同的图像，无法保证一致性。

### 5.2 隐空间语义插值

DDIM 的确定性生成使得**在潜空间 $\mathbf{x}_T$ 中进行插值**具有语义意义：
对两张图像的编码 $\mathbf{x}_T^{(0)}, \mathbf{x}_T^{(1)}$，使用**球面线性插值（SLERP）**：

$$\mathbf{x}_T^{(\alpha)} = \frac{\sin((1-\alpha)\theta)}{\sin\theta}\mathbf{x}_T^{(0)} + \frac{\sin(\alpha\theta)}{\sin\theta}\mathbf{x}_T^{(1)}, \quad \theta = \arccos\frac{(\mathbf{x}_T^{(0)})^\top \mathbf{x}_T^{(1)}}{\|\mathbf{x}_T^{(0)}\|\|\mathbf{x}_T^{(1)}\|} \tag{11}$$

再通过 DDIM 解码得到插值图像，实现姿态、发型、肤色、表情等语义属性的平滑过渡。

**DDIM vs DDPM 插值对比**

- **DDIM（隐空间插值）**：在高维 $\mathbf{x}_T$ 空间插值，语义上平滑，支持各种属性的自然过渡，类似 GAN 的隐空间操控。
- **DDPM（图像空间插值）**：由于随机生成过程，相同 $\mathbf{x}_T$ 插值会引入噪声伪影，语义插值效果差。若要近似插值需要对所有 $T$ 个噪声插值（不实用）。

### 5.3 图像重建（Reconstruction）

由于 DDIM 的 ODE 是可逆的，可以：

1. 用 DDIM 编码器将 $\mathbf{x}_0 \to \mathbf{x}_T$（运行前向 ODE）；
2. 再用 DDIM 解码器将 $\mathbf{x}_T \to \mathbf{x}_0'$（运行反向 ODE）；
3. 重建误差随步数 $S$ 增加而减小：$S = 1000$ 时误差约 $10^{-4}$。

| 步数 $S$ | 10 | 20 | 50 | 100 | 200 | 500 | 1000 |
|---|---|---|---|---|---|---|---|
| 重建 MSE ($\times 10^{-4}$) | 140 | 65 | 23 | 9 | 4 | 1 | 1 |

DDPM 由于随机性，**无法精确重建**图像（每次解码都会得到不同结果）。

## §6 实验与结果

## 6.1 实验设置

- **模型**：使用 DDPM 原始预训练模型，不重新训练，仅改变采样过程。
- **数据集**：CIFAR10（$32 \times 32$）、CelebA（$64 \times 64$）、LSUN Bedroom/Church（$256 \times 256$）。
- **随机性控制**：超参数 $\eta$ 控制采样随机性（$\eta = 0$ 为 DDIM，$\eta = 1$ 为 DDPM）。
- **评估指标**：FID（越低越好）、时钟时间（单 Nvidia 2080 Ti GPU）。

## 6.2 样本质量与效率

| 方法 | | CIFAR10 FID（不同步数 $S$） | | | | |
|---|---|---|---|---|---|---|
| $\eta$ | 类型 | 10 | 20 | 50 | 100 | 1000 |
| 0.0 | **DDIM（本文）** | **13.36** | **6.84** | **4.67** | **4.16** | 4.04 |
| 0.2 | 略随机 | 14.04 | 7.11 | 4.77 | 4.25 | 4.09 |
| 0.5 | 中等随机 | 16.66 | 8.35 | 5.25 | 4.46 | 4.29 |
| 1.0 | DDPM | 41.07 | 18.36 | 8.01 | 5.78 | 4.73 |
| $\hat{\sigma}$ | DDPM（大方差） | 367.43 | 133.37 | 32.72 | 9.99 | **3.17** |

- DDIM（$\eta = 0$）在**少步数**（$S = 10 \sim 100$）时大幅优于 DDPM，FID 在 $S = 20$ 时仅为 6.84，而 DDPM 需要 1000 步才能达到 4.73。
- 在完整 1000 步下，DDPM（$\hat{\sigma}$）的 FID（3.17）略优于 DDIM（4.04），但 DDIM 以 50 步即可达到接近的质量（4.67）。
- DDPM 大方差版本（$\hat{\sigma}$）在少步数下表现极差（$S = 10$ 时 FID=367），**完全不适合加速采样**；而 DDIM 保持稳定的质量。

### 6.3 LSUN 256×256 结果

| 方法 | 10 步 | 20 步 | 50 步 | 100 步 |
|---|---|---|---|---|
| DDIM (Bedroom) | 16.95 | 8.89 | 6.75 | 6.62 |
| DDPM (Bedroom) | 42.78 | 22.77 | 10.81 | 6.81 |
| DDIM (Church) | 19.45 | 12.47 | 10.84 | 10.58 |
| DDPM (Church) | 51.56 | 23.37 | 11.16 | 8.27 |

DDPM 1000 步基准：Bedroom FID = 6.36，Church FID = 7.89。DDIM 以 100 步即可达到或超越该基准。

### 6.4 速度对比

采样时间随步数**线性增长**，DDIM 的加速效果直接体现在时钟时间上：

| 采样步数 | CIFAR10 50k 张（小时） | Bedroom 50k 张（小时） |
|---|---|---|
| 10 步 | 0.2 | 10 |
| 20 步 | 0.5 | 30 |
| 50 步 | 1.0 | 100 |
| 100 步 | 2.0 | 200 |
| 1000 步（DDPM 基准） | 20 | 1000 |

## §7 DDPM 与 DDIM 的深度对比

| 维度 | DDPM | DDIM |
|---|---|---|
| 前向过程 | 马尔可夫扩散 | 非马尔可夫（通用） |
| 生成过程 | 随机马尔可夫链 | 确定性 ODE（$\eta = 0$） |
| 采样步数 | 必须 $T = 1000$ 步 | 可选子序列 $S \ll T$ |
| 训练方式 | 从头训练 | 复用 DDPM 权重 |
| 一致性 | × 不同步数结果不同 | ✓ 高层特征一致 |
| 隐空间插值 | 效果差 | ✓ 语义平滑插值 |
| 图像编码/重建 | × 不可逆 | ✓ 近似可逆 |
| 少步数质量 | 极差（FID 急剧恶化） | 稳定高质量 |
| 满步质量（1000 步） | 略优（FID 3.17） | 略逊（FID 4.04） |

# §8 总结与思考

## 8.1 核心贡献回顾

**DDIM 的四大核心贡献**

1. **理论推广**：证明 DDPM 训练目标对一大类非马尔可夫前向过程均成立，建立了统一的推断框架，揭示了扩散模型更深层的结构。
2. **极致加速**：在**无需重新训练**的前提下，实现 10×–50× 采样加速，将扩散模型的实用性提升到全新高度。
3. **确定性生成**：首次提出确定性扩散采样器（DDIM），赋予扩散模型类似 GAN 的隐空间语义操控能力（插值、重建）。
4. **ODE 视角**：将 DDIM 解释为常微分方程的 Euler 积分，开创了用 ODE 求解器加速扩散采样的研究方向（DPM-Solver 等的前驱）。

## 8.2 局限性

**注意**

- **满步质量略逊**：当步数足够多（$S = 1000$）时，DDIM 的 FID 略高于 DDPM（4.04 vs 3.17），表明随机性在完整生成中仍有一定优势。
- **重建误差非零**：虽然误差随步数减少，少步数时重建误差仍较明显（$S = 10$ 时 MSE $= 0.014$），与标准可逆模型（如 Normalizing Flow）仍有差距。
- **ODE 积分阶数低**：DDIM 本质是 Euler 积分（一阶法），对于相同精度需要更多步；更高阶 ODE 求解器理论上可进一步提升效率（后续 DEIS、DPM-Solver 验证了这一点）。
- **参数共享假设**：定理 1 的" 无需重训练" 结论严格依赖于参数**不跨时间步共享**的条件；而 DDPM 实现中权重是共享的（通过时间嵌入区分），这在理论上引入了细微差异（但实验表明影响可忽略）。

## 8.3 后续影响

DDIM 开创了扩散模型加速采样的研究方向，直接催生了一系列重要工作：

- **DPM-Solver / DPM-Solver++**（Lu et al., 2022）：用高阶 ODE 求解器替换 DDIM 的 Euler 积分，10 步内即可获得高质量样本。
- **DEIS**（Zhang & Chen, 2022）：指数积分器，进一步优化采样效率。
- **Consistency Models**（Song et al., 2023）：将 ODE 轨迹上的一致性性质显式编入训练目标，实现单步/少步生成。
- **Stable Diffusion 等**：DDIM 采样器（50–100 步）成为 Stable Diffusion 等大规模图像生成系统的默认采样策略，广泛部署于工业界。
- **图像编辑应用**：DDIM Inversion（反向 DDIM 编码）成为 Prompt-to-Prompt、Null-Text Inversion 等图像编辑方法的基础工具。

**核心摘要**

DDIM 以一个深刻的理论洞察——**训练目标仅依赖边缘分布**——为切入点，推导出确定性生成过程，将扩散模型的采样速度从" 不可用" 跨越到" 实用"。它不仅解决了 DDPM 最致命的工程缺陷，更从根本上改变了扩散模型的研究范式：将生成过程视为 ODE 求解问题，将模型与采样器解耦。这一思想影响深远，是现代扩散模型生态（Stable Diffusion、SDXL、Sora 等）不可或缺的基础。

# §9 个人理解与思考

**DDIM 如何直击 DDPM 的痛点？**

1. **DDPM 的痛点**:DDPM 生成图像的过程是一个马尔科夫链，必须从 $x_T$ 到 $x_0$ 一步一步走，每一步都需要通过 U-Net 进行一次前向传播。DDPM 的训练目标本质上只要求模型学习好一个条件：给定任意时间步 t 的噪声图像 $x_t$，模型能够预测出所添加的噪声 $\epsilon$。
2. **DDIM 的策略**：设计一个全新的、非马尔可夫的生成过程，通过去噪扩散隐式模型，将模型的" 训练" 和 "采样" 彻底解耦。

**什么是非马尔可夫过程？**

1. **马尔可夫性质**: 系统的下一个状态只取决于当前的状态，而与过去状态无关。
2. **DDIM 的非马尔可夫过程**：DDIM 定义了一个新的前向过程，在新的过程中 $x_{t-1}$ 的分布不仅依赖于 $x_t$, 还直接依赖于 $x_0$。虽然过程是非马尔可夫的，但是 DDIM 巧妙地设计了条件分布，使得每一步的边缘分布仍然和 DDPM 一样，这正是它能复用 DDPM 模型的关键。

**关于核心参数 $\sigma$ 与 $\eta$**

1. **$\sigma_t$ 的作用**：控制噪声的随机强度。在 DDIM 的通用采样公式中，$\sigma_t$ 是添加到每一步生成过程的随机噪声项。
2. **从随机扩散（$\eta$=1）到确定性映射（$\eta$=0）**: 当 $\eta$=1 的时候，DDIM 退化为 DDPM，此时，$\sigma_t$ 的值就恰好是 DDPM 中反向过程要求的方差; 当 $\eta$=0 的时候，DDIM 成为真正的" 隐式模型"，此时整个生成过程就变得完全确定性。给定一个初始的随机噪声 $x_T$。当 $\eta$ 在 0 和 1 之间的之后，生成过程包含一定程度的随机性，但是其强度小于 DDPM。