DDPM 论文阅读笔记

Denoising Diffusion Probabilistic Models

Jonathan Ho, Ajay Jain, Pieter Abbeel NeurIPS 2020

阅读笔记整理

2026 年 3 月 1 日

§1 论文基本信息

发表会议	NeurIPS 2020
作者单位	UC Berkeley
关键词	扩散概率模型 (Diffusion Probabilistic Models)、去噪分数匹配 (Denoising Score Matching)、Langevin 动力学、图像生成
开源代码	`https://github.com/hojonathanho/diffusion`
论文链接	`arXiv:2006.11239v2`

核心摘要

本文提出了基于 **去噪扩散概率模型（DDPM）**的高质量图像生成方法。其核心思想是：通过训练一个神经网络来逐步**逆转**一个将数据加噪为高斯噪声的马尔可夫链过程，从而实现从纯噪声到真实图像的生成。论文的关键贡献在于发现了扩散模型与**去噪分数匹配**及 **Langevin 动力学**之间深刻的数学等价性，并由此推导出一个简化的训练目标 L_{simple}。在 CIFAR10 数据集上取得了 FID 分数 3.17 的当时 SOTA 性能，同时在 256×256 LSUN 上达到了与 ProgressiveGAN 相当的样本质量。

§2 研究背景与动机

2.1 问题出发点

深度生成模型家族众多，各有优劣：GAN 生成质量高但训练不稳定；VAE 训练稳定但生成质量有限；Flow 模型可以精确计算似然但架构受限。**扩散概率模型**作为一类基于非平衡热力学的潜变量模型，此前虽已被提出，但从未展示出生成高质量样本的能力。

扩散模型的核心直觉

扩散过程的灵感来自非平衡热力学（Non-equilibrium Thermodynamics）：

- **正向过程（加噪）**：就像把一滴墨水滴入清水，墨水分子会自发地向四周扩散，最终均匀混合——数据逐渐被高斯噪声淹没。
- **反向过程（去噪）**：如果我们能精确地逆转每一步分子的运动，就能让清水重新变回纯净的墨滴——从纯噪声中逐步恢复出真实数据。
- **神经网络的作用**：直接逆转物理过程不现实，但我们可以训练神经网络来学习这个逆向转移概率。

2.2 论文的核心贡献

1. **高质量生成**：首次证明扩散模型能够生成与 GAN 相媲美的高质量图像。
2. **关键数学联系**：揭示了扩散模型的特定参数化方案与**多噪声尺度下的去噪分数匹配**在数学上等价，与 **Langevin 动力学**采样在形式上一致。
3. **简化训练目标**：推导出形式简洁、效果优越的目标函数 L_{simple}。
4. **渐进式压缩解释**：提出将采样过程解读为一种渐进式有损解压缩方案。

§3 方法详解

3.1 模型框架：两个互逆的马尔可夫链

DDPM 的核心是两条方向相反的马尔可夫链，如下图所示：

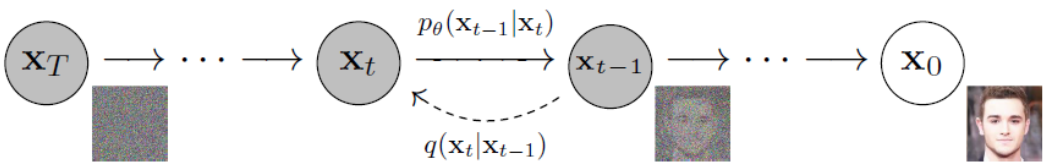

Figure 2: The directed graphical model considered in this work.

整体框架定义了一个联合分布 $p_\theta(\mathbf{x}_{0:T})$，其中 $\mathbf{x}_0$ 是真实数据，$\mathbf{x}_T$ 是标准高斯噪声，$T = 1000$。

两条马尔可夫链的角色

- **正向过程 / 扩散过程 q（固定，无参数）**：将数据 $\mathbf{x}_0$ 逐步加噪，直至变成纯高斯噪声 $\mathbf{x}_T$，这一过程是**固定的**，不需要学习。
- **反向过程 p_θ（可学习）**：从噪声 $\mathbf{x}_T \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 出发，通过神经网络参数化的逐步去噪，最终生成数据样本 $\mathbf{x}_0$。这是模型需要**训练学习**的部分。

3.2 正向过程 (Forward Process)

正向过程定义

$$q(\mathbf{x}_{1:T}|\mathbf{x}_0) := \prod_{t=1}^{T} q(\mathbf{x}_t|\mathbf{x}_{t-1}) \tag{1}$$

$$q(\mathbf{x}_t|\mathbf{x}_{t-1}) := \mathcal{N}\left(\mathbf{x}_t;\ \sqrt{1-\beta_t}\,\mathbf{x}_{t-1},\ \beta_t\mathbf{I}\right) \tag{2}$$

符号说明：

- $q(\mathbf{x}_{1:T}|\mathbf{x}_0)$：给定原始数据 $\mathbf{x}_0$，正向过程所定义的潜变量联合分布（马尔可夫链）。
- $\beta_t \in (0, 1)$：第 t 步的**噪声方差调度（variance schedule）**，控制每步加入的噪声量。论文设定为从 $\beta_1 = 10^{-4}$ 到 $\beta_T = 0.02$ 的线性增长序列，并作为固定超参数。
- $\sqrt{1-\beta_t}\,\mathbf{x}_{t-1}$：均值项——对上一步信号做轻微缩放（$< 1$），以防止随步数增加方差爆炸。
- $\beta_t\mathbf{I}$：方差项——每步注入方差为 β_t 的各向同性高斯噪声。

式 (1) 表明，整个加噪的过程，是一个由 T 个条件高斯分布串联组成的马尔可夫链，每一步都在前一步的基础上加入少量噪声。

式 (2) 表明,在已知前一步的情况下,当前步骤的分布是一个均值为 $\sqrt{1-\beta_t}\,\mathbf{x}_{t-1}$、方差为 $\beta_t\mathbf{I}$ 的高斯分布。

使用高斯分布的好处，是它具有良好的数学性质，尤其是**闭合性**，使得后续的训练目标推导和采样过程都能得到解析解。

3.2.1 关键性质：任意时刻的闭合形式采样

正向过程最重要的数学性质是，无需逐步迭代，可以**直接从 $\mathbf{x}_0$ 采样得到任意时刻 t 的 $\mathbf{x}_t$**。

正向过程的闭合形式（重参数化）

定义 $\alpha_t := 1-\beta_t$，$\bar{\alpha}_t := \prod_{s=1}^{t}\alpha_s$，则：

$$q(\mathbf{x}_t|\mathbf{x}_0) = \mathcal{N}\big(\mathbf{x}_t;\ \sqrt{\bar{\alpha}_t}\,\mathbf{x}_0,\ (1-\bar{\alpha}_t)\mathbf{I}\big) \tag{3}$$

等价地，可以用重参数化技巧写为：

$$\mathbf{x}_t = \sqrt{\bar{\alpha}_t}\,\mathbf{x}_0 + \sqrt{1-\bar{\alpha}_t}\,\boldsymbol{\epsilon}, \quad \boldsymbol{\epsilon}\sim\mathcal{N}(\mathbf{0},\mathbf{I}) \tag{4}$$

符号说明：

- $\alpha_t = 1-\beta_t$：每步”保留”原始信号的比例。
- $\bar{\alpha}_t = \prod_{s=1}^{t}(1-\beta_s)$：$t$ 步之后原始信号的累积保留比例。当 $t\to T$ 时，$\bar{\alpha}_T\approx 0$，信号被完全湮没。
- $\sqrt{\bar{\alpha}_t}\,\mathbf{x}_0$：$\mathbf{x}_t$ 中来自原始数据的成分（信号部分）。
- $\sqrt{1-\bar{\alpha}_t}\,\boldsymbol{\epsilon}$：$\mathbf{x}_t$ 中叠加的噪声成分。
- 这一性质使得训练时可以高效地直接采样任意噪声步的样本，无需逐步迭代 T 次。

固定 β_t 使正向后验 q 没有可学习参数，即 L_T 在训练中是常数，可被忽略。同时，β_t 足够小时（相对于 $[-1,1]$ 缩放的数据），正向与反向过程具有相同的函数形式（均为条件高斯），这保证了用高斯分布参数化反向过程的合理性。

3.3 反向过程 (Reverse Process)

反向过程定义

$$p_\theta(\mathbf{x}_{0:T}) := p(\mathbf{x}_T) \prod_{t=1}^{T} p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t) \tag{5}$$

$$p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t) := \mathcal{N}(\mathbf{x}_{t-1};\, \boldsymbol{\mu}_\theta(\mathbf{x}_t, t),\, \boldsymbol{\Sigma}_\theta(\mathbf{x}_t, t)) \tag{6}$$

其中先验为 $p(\mathbf{x}_T) = \mathcal{N}(\mathbf{x}_T; \mathbf{0}, \mathbf{I})$。

符号说明：

- $p_\theta(\mathbf{x}_{0:T})$：由神经网络 θ 参数化的**反向过程联合分布**，也称为生成模型。
- $\boldsymbol{\mu}_\theta(\mathbf{x}_t, t)$：神经网络预测的反向转移均值，以当前含噪样本 $\mathbf{x}_t$ 和时间步 t 为输入。
- $\boldsymbol{\Sigma}_\theta(\mathbf{x}_t, t)$：反向转移方差，论文实验中**固定为不可学习的时间相关常数** $\sigma_t^2\mathbf{I}$，避免了学习方差导致的不稳定性。

3.3.1 方差的设定

论文将 $\boldsymbol{\Sigma}_\theta(\mathbf{x}_t, t) = \sigma_t^2\mathbf{I}$ 固定为常数，并考虑两种选择：

方差选择	表达式	最优场景
上界	$\sigma_t^2 = \beta_t$	数据先验为 $\mathcal{N}(\mathbf{0}, \mathbf{I})$
下界	$\sigma_t^2 = \tilde{\beta}_t = \frac{1-\bar{\alpha}_{t-1}}{1-\bar{\alpha}_t}\beta_t$	数据为确定性单点

两种选择对应反向过程熵的上下界，实验结果相近。

3.4 训练目标：变分下界 (Variational Lower Bound)

原始变分下界（负对数似然上界）

$$\mathbb{E}\left[-\log p_\theta(\mathbf{x}_0)\right] \le \mathbb{E}_q\left[-\log \frac{p_\theta(\mathbf{x}_{0:T})}{q(\mathbf{x}_{1:T}|\mathbf{x}_0)}\right] =: L \tag{7}$$

3.4.1 变分下界的精细分解

通过 Bayes 定理对正向过程后验 $q(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0)$ 进行条件化（因为以 $\mathbf{x}_0$ 为条件时，该后验有解析闭合形式），L 可以分解为若干 KL 散度项之和：

变分下界的分解形式

$$L = \underbrace{D_{\mathrm{KL}}(q(\mathbf{x}_T|\mathbf{x}_0) \,\|\, p(\mathbf{x}_T))}_{L_T} + \sum_{t=2}^{T} \underbrace{D_{\mathrm{KL}}(q(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0) \,\|\, p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t))}_{L_{t-1}} - \underbrace{\log p_\theta(\mathbf{x}_0|\mathbf{x}_1)}_{L_0} \tag{8}$$

三类损失项说明：

- $L_T = D_{\mathrm{KL}}(q(\mathbf{x}_T|\mathbf{x}_0) \,\|\, p(\mathbf{x}_T))$：衡量正向过程的末态分布与先验 $\mathcal{N}(\mathbf{0}, \mathbf{I})$ 的差距。由于 β_t 固定且正向过程参数化使 $\bar{\alpha}_T \approx 0$，此项近似为零（约 10^{-5} bits/dim），是训练中的**常数**，可忽略。
- $L_{t-1} = D_{\mathrm{KL}}(q(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0) \,\|\, p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t))$：训练的**核心损失**。衡量学习的反向转移与真实的正向过程后验之间的距离。由于两者均为高斯分布，此 KL 散度可以解析计算，无需高方差的蒙特卡洛估计。
- $L_0 = -\log p_\theta(\mathbf{x}_0|\mathbf{x}_1)$：最后一步的**重建损失**，论文通过离散化解码器处理（将连续高斯离散化到像素值网格）。

3.4.2 正向过程后验的解析解

L_{t-1} 中需要 $q(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0)$ 的解析表达式：

正向过程的 Bayes 后验（可解析计算）

$$q(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0) = \mathcal{N}\Big(\mathbf{x}_{t-1};\, \tilde{\boldsymbol{\mu}}_t(\mathbf{x}_t, \mathbf{x}_0),\, \tilde{\beta}_t \mathbf{I}\Big) \tag{9}$$

$$\tilde{\boldsymbol{\mu}}_t(\mathbf{x}_t, \mathbf{x}_0) := \frac{\sqrt{\bar{\alpha}_{t-1}}\,\beta_t}{1-\bar{\alpha}_t}\,\mathbf{x}_0 + \frac{\sqrt{\alpha_t}(1-\bar{\alpha}_{t-1})}{1-\bar{\alpha}_t}\,\mathbf{x}_t \tag{10}$$

$$\tilde{\beta}_t := \frac{1-\bar{\alpha}_{t-1}}{1-\bar{\alpha}_t}\,\beta_t \tag{11}$$

符号说明：

- $\tilde{\boldsymbol{\mu}}_t(\mathbf{x}_t, \mathbf{x}_0)$：条件于 $\mathbf{x}_0$ 时，正向过程在 $t-1$ 时刻的后验均值，是 $\mathbf{x}_0$（原始数据）和 $\mathbf{x}_t$（当前噪声数据）的**线性组合**。
- 第一项 $\frac{\sqrt{\bar{\alpha}_{t-1}}\beta_t}{1-\bar{\alpha}_t}\mathbf{x}_0$：来自原始数据 $\mathbf{x}_0$ 的”信号牵引”。
- 第二项 $\frac{\sqrt{\alpha_t}(1-\bar{\alpha}_{t-1})}{1-\bar{\alpha}_t}\mathbf{x}_t$：来自当前含噪观测 $\mathbf{x}_t$ 的”位置约束”。
- $\tilde{\beta}_t$：后验方差，介于 0 和 β_t 之间，可视为反向过程熵的下界。

3.5 均值参数化

3.5.1 直接参数化

最直接的做法：令神经网络直接预测后验均值 $\tilde{\boldsymbol{\mu}}_t$。此时 L_{t-1} 简化为：

均值参数化的损失函数

$$L_{t-1} = \mathbb{E}_q\left[\frac{1}{2\sigma_t^2}\left\|\tilde{\boldsymbol{\mu}}_t(\mathbf{x}_t, \mathbf{x}_0) - \boldsymbol{\mu}_\theta(\mathbf{x}_t, t)\right\|^2\right] + C \tag{12}$$

3.5.2 改进参数化

将式 (4) 代入式 (10)，可以将 $\tilde{\boldsymbol{\mu}}_t$ 改写为关于 $\boldsymbol{\epsilon}$ 的函数，从而推导出一种更自然的参数化方式。

由式 (4)：$\mathbf{x}_0 = \frac{1}{\sqrt{\bar{\alpha}_t}}\left(\mathbf{x}_t - \sqrt{1-\bar{\alpha}_t}\,\boldsymbol{\epsilon}\right)$，代入式 (10) 化简得：

$$\tilde{\boldsymbol{\mu}}_t(\mathbf{x}_t, \mathbf{x}_0) = \frac{1}{\sqrt{\alpha_t}}\left(\mathbf{x}_t - \frac{\beta_t}{\sqrt{1-\bar{\alpha}_t}}\boldsymbol{\epsilon}\right) \tag{13}$$

因此，令神经网络 $\boldsymbol{\epsilon}_\theta$ 预测噪声 $\boldsymbol{\epsilon}$，对应的均值参数化为：

$$\boldsymbol{\mu}_\theta(\mathbf{x}_t, t) = \frac{1}{\sqrt{\alpha_t}}\left(\mathbf{x}_t - \frac{\beta_t}{\sqrt{1-\bar{\alpha}_t}}\boldsymbol{\epsilon}_\theta(\mathbf{x}_t, t)\right) \tag{14}$$

对应的损失项为：

$$L_{t-1} - C = \mathbb{E}_{\mathbf{x}_0,\boldsymbol{\epsilon}}\left[\frac{\beta_t^2}{2\sigma_t^2\alpha_t(1-\bar{\alpha}_t)}\left\|\boldsymbol{\epsilon} - \boldsymbol{\epsilon}_\theta\left(\sqrt{\bar{\alpha}_t}\mathbf{x}_0 + \sqrt{1-\bar{\alpha}_t}\boldsymbol{\epsilon},\, t\right)\right\|^2\right] \tag{15}$$

关键理解：

- $\boldsymbol{\epsilon}_\theta(\mathbf{x}_t, t)$：神经网络的任务变为预测在第 t 步中叠加的噪声 $\boldsymbol{\epsilon}$，而非预测去噪后的数据。
- 式 (15) 揭示：优化此参数化等价于在多个噪声尺度 t 上做**去噪分数匹配（Denoising Score Matching）**——因为数据分布的分数函数（score function）$\nabla_{\mathbf{x}_t}\log q(\mathbf{x}_t) \propto -\boldsymbol{\epsilon}$。
- 采样 $\mathbf{x}_{t-1} \sim p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t)$ 等价于 Langevin 动力学的一步更新，其中 $\boldsymbol{\epsilon}_\theta$ 扮演了数据分布梯度的角色。

3.6 简化训练目标 L_{simple}

式 (15) 中存在与 t 相关的权重系数 $\frac{\beta_t^2}{2\sigma_t^2\alpha_t(1-\bar{\alpha}_t)}$，论文提出忽略此权重，使用均匀加权的简化目标：

简化训练目标（论文最终使用）

$$L_{\text{simple}}(\theta) := \mathbb{E}_{t,\mathbf{x}_0,\boldsymbol{\epsilon}}\left[\left\|\boldsymbol{\epsilon} - \boldsymbol{\epsilon}_\theta\left(\sqrt{\bar{\alpha}_t}\,\mathbf{x}_0 + \sqrt{1-\bar{\alpha}_t}\,\boldsymbol{\epsilon},\, t\right)\right\|^2\right] \tag{16}$$

其中 $t \sim \text{Uniform}(\{1,\ldots,T\})$，$\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0},\mathbf{I})$，$\mathbf{x}_0 \sim q(\mathbf{x}_0)$。

为什么简化目标效果更好？

- 原始权重使小 t（少噪声步）的损失被过度放大，让模型在极轻度去噪任务上浪费容量。
- L_{simple} 相当于**对小 t 项降权**，使模型将更多注意力集中在困难的高噪声去噪任务上（大 t 项），从而提升生成质量。
- 代价是：L_{simple} 比真实变分下界有更大的码长，日志似然分数不如直接优化 L（但样本质量更优）。

注意

L_{simple} 是一个**加权**的变分下界，通过改变不同噪声尺度损失项的权重来强调更困难的去噪任务。实验证明，该简化目标在样本质量上显著优于真实变分下界（FID: 3.17 vs 13.51），尽管在负对数似然方面略逊一筹。

3.7 完整算法

Algorithm 1 训练过程 (Training)

1: **repeat**
2: 从数据集采样原始数据：$\mathbf{x}_0 \sim q(\mathbf{x}_0)$
3: 均匀采样时间步：$t \sim \text{Uniform}(\{1,\ldots,T\})$
4: 采样标准高斯噪声：$\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0},\mathbf{I})$
5: **计算加噪样本**（利用正向过程闭合形式，无需逐步迭代）：
$\mathbf{x}_t = \sqrt{\bar{\alpha}_t}\,\mathbf{x}_0 + \sqrt{1-\bar{\alpha}_t}\,\boldsymbol{\epsilon}$
6: **梯度下降**，最小化预测噪声与真实噪声的均方误差：
$\nabla_\theta \left\|\boldsymbol{\epsilon} - \boldsymbol{\epsilon}_\theta(\mathbf{x}_t,\, t)\right\|^2$
7: **until** 收敛

Algorithm 2 采样过程 (Sampling)

1: 从先验采样：$\mathbf{x}_T \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$
2: **for** $t = T, T-1, \ldots, 1$ **do**
3: 如果 $t > 1$ 则采样 $\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$，否则 $\mathbf{z} = \mathbf{0}$
4: **逆向去噪一步**（使用式 (??)）：
$$\mathbf{x}_{t-1} = \frac{1}{\sqrt{\alpha_t}}\left(\mathbf{x}_t - \frac{\beta_t}{\sqrt{1-\bar{\alpha}_t}}\boldsymbol{\epsilon}_\theta(\mathbf{x}_t, t)\right) + \sigma_t \mathbf{z}$$
5: **end for**
6: **return** $\mathbf{x}_0$

算法中关键量的解读：

- $\frac{1}{\sqrt{\alpha_t}}(\cdots)$：将网络预测的噪声从 $\mathbf{x}_t$ 中" 减去" 一部分，得到对 $\mathbf{x}_{t-1}$ 的均值估计。
- $\frac{\beta_t}{\sqrt{1-\bar{\alpha}_t}}\boldsymbol{\epsilon}_\theta(\mathbf{x}_t, t)$：从 $\mathbf{x}_t$ 中减去的噪声量。系数 $\frac{\beta_t}{\sqrt{1-\bar{\alpha}_t}}$ 由 β_t（本步噪声）和 $\sqrt{1-\bar{\alpha}_t}$（累积噪声）共同决定。
- $\sigma_t \mathbf{z}$：添加的随机噪声，保证反向过程的随机性，对应 Langevin 动力学中的热扰动项。最后一步（$t = 1$）不加噪声，直接输出 $\boldsymbol{\mu}_\theta$。

3.8 神经网络架构

ϵ_θ 的网络架构设计

- **主干**：U-Net 结构（参考 PixelCNN++ 的骨架），基于 Wide ResNet，结合编码器-解码器与跳跃连接（skip connections）。
- **时间编码**：使用 Transformer 正弦位置编码将时间步 t 编码为向量，**加入到每个残差块中**（而非仅在归一化层），使网络感知当前去噪阶段。
- **归一化**：用 **Group Normalization** 替换 Weight Normalization，简化实现。
- **自注意力**：在 16×16 特征图分辨率层之间插入自注意力块，捕获长程空间依赖。
- **分辨率处理**：CIFAR10 模型使用 4 档分辨率（$32 \to 16 \to 8 \to 4$），256×256 模型使用 6 档。
- **参数量**：CIFAR10 模型约 3570 万参数；LSUN/CelebA-HQ 模型约 1.14 亿参数；超大 LSUN Bedroom 模型约 2.56 亿参数。
- **参数共享**：同一套网络权重 θ 在所有时间步 t 间共享，通过时间嵌入区分不同步骤。

3.9 数据缩放与离散解码器 L_0

图像像素值（整数 $\{0, 1, \ldots, 255\}$）被线性缩放至 $[-1, 1]$，确保与先验 $\mathcal{N}(\mathbf{0}, \mathbf{I})$ 量纲一致。最后一步使用离散化解码器：

离散化解码器 $p_\theta(\mathbf{x}_0|\mathbf{x}_1)$

$$p_\theta(\mathbf{x}_0|\mathbf{x}_1) = \prod_{i=1}^{D} \int_{\delta^-(x_0^i)}^{\delta^+(x_0^i)} \mathcal{N}\big(x;\, \mu_\theta^i(\mathbf{x}_1, 1),\, \sigma_1^2\big)\, \mathrm{d}x \tag{17}$$

其中 $\delta^+(x) = x + \frac{1}{255}$（若 $x < 1$，否则 $+\infty$），$\delta^-(x) = x - \frac{1}{255}$（若 $x > -1$，否则 $-\infty$）。

此设计保证变分下界是离散数据无损码长，无需对数据添加连续噪声或引入 Jacobian 修正项。

§4 与去噪分数匹配和 Langevin 动力学的等价性

这是本文最重要的理论发现之一，揭示了三类看似不同方法之间深刻的内在联系。

三种方法的等价性

- **扩散模型变分推断**（本文）：优化 L_{simple}，即训练 $\boldsymbol{\epsilon}_\theta$ 预测各时刻的噪声。
- **多尺度去噪分数匹配（NCSN/NCSNv2）**：训练网络估计各噪声尺度下数据分布的分数函数 $\nabla_{\mathbf{x}} \log q_\sigma(\mathbf{x})$。
- **退火 Langevin 动力学采样**：从大噪声到小噪声逐步运行 Langevin 采样步骤：$\mathbf{x}_{t-1} \leftarrow \mathbf{x}_t + \frac{\eta}{2} \nabla_{\mathbf{x}_t} \log q(\mathbf{x}_t) + \sqrt{\eta}\, \mathbf{z}$。

关键等价关系：$\boldsymbol{\epsilon}_\theta(\mathbf{x}_t, t) \approx -\sqrt{1 - \bar{\alpha}_t}\, \nabla_{\mathbf{x}_t} \log q(\mathbf{x}_t)$，即神经网络预测的噪声正比于负分数函数。

- 扩散模型用**变分推断框架**直接训练 Langevin 动力学采样器，而 NCSN 是在训练后才" 拼接" 一个 Langevin 采样器（系数手工设定）。
- 扩散模型的训练目标**直接优化了生成器的质量度量**，具有理论保证；NCSN 则缺乏这一保证。
- 这种等价性说明了为什么 L_{simple}（去噪自编码目标）有效：它本质上是在所有噪声尺度上同时训练分数估计器。

§5 实验与结果

5.1 实验设置

- **扩散步数**：$T = 1000$（与 NCSN 保持一致，便于比较）。
- **噪声调度**：β_t 从 10^{-4} 到 0.02 线性增长，相对于 $[-1, 1]$ 缩放的数据足够小，保证正向/反向函数形式近似。
- **计算资源**：TPU v3-8（约等于 8 张 V100 GPU）。CIFAR10 模型 10.6 小时训练至收敛（800k 步，每步 21 steps/s at bs=128）；256×256 模型采样 128 张需约 300 秒。
- **训练细节**：Adam 优化器（$\beta_1 = 0.9, \beta_2 = 0.999$），学习率 2×10^{-4}（大图像降至 2×10^{-5}），EMA 衰减率 0.9999，CIFAR10 dropout 率 0.1。

5.2 样本质量对比

模型	IS ↑	FID ↓	NLL (bits/dim) ↓
条件生成模型 *(Conditional)*			
BigGAN	9.22	14.73	—
StyleGAN2 + ADA	10.06	<u>2.67</u>	—
无条件生成模型 *(Unconditional)*			
NCSN	8.87	25.32	—
NCSNv2	—	31.75	—
SNGAN-DDLS	9.09	15.42	—
StyleGAN2 + ADA	9.74	3.26	—
Gated PixelCNN	4.60	65.93	3.03
Sparse Transformer	—	2.80	—
Ours (L, fixed $\mathbf{\Sigma}$)	7.67	13.51	≤ 3.70
Ours (L_{simple})	**9.46**	**3.17**	≤ 3.75

- L_{simple} 在无条件生成中取得 **FID 3.17**，超越了所有无条件生成模型，甚至优于部分条件生成模型（如 BigGAN）。
- 训练真实变分下界 L 的版本负对数似然更好（≤ 3.70 vs ≤ 3.75），但样本质量（FID 13.51）远不如 L_{simple}，验证了简化目标的必要性。
- 测试集 FID 为 5.24，也优于许多其他模型的训练集 FID，说明**模型未过拟合**（训练/测试 NLL 差距 ≤ 0.03 bits/dim）。

5.3 反向过程参数化消融实验

预测目标	训练目标	IS ↑	FID ↓
预测 $\tilde{\boldsymbol{\mu}}$（基线）	L，可学习对角 $\boldsymbol{\Sigma}$	7.28	23.69
	L，固定各向同性 $\boldsymbol{\Sigma}$	8.06	13.22
	$\|\tilde{\boldsymbol{\mu}} - \boldsymbol{\mu}_\theta\|^2$	不稳定，样本差	
预测 $\boldsymbol{\epsilon}$（本文）	L，可学习对角 $\boldsymbol{\Sigma}$	不稳定，样本差	
	L，固定各向同性 $\boldsymbol{\Sigma}$	7.67	13.51
	L_{simple}（本文最终选择）	**9.46**	**3.17**

消融实验揭示：**可学习方差**会导致训练不稳定；预测 $\boldsymbol{\epsilon}$ 配合 L_{simple} 的组合在所有配置中性能最优。

5.4 LSUN 256×256 结果

模型	Bedroom FID ↓	Church FID ↓	Cat FID ↓
ProgressiveGAN	8.34	6.42	37.52
StyleGAN	2.65	4.21	8.53
StyleGAN2	—	3.86	6.93
Ours (L_{simple})	6.36	7.89	19.75
Ours (L_{simple}，大模型)	**4.90**	—	—

在 LSUN 上，DDPM 的质量接近 ProgressiveGAN，但仍低于 StyleGAN/StyleGAN2。这暗示扩散模型在大分辨率或复杂场景下仍有提升空间（参数量更大的模型有明显改善：Bedroom FID 从 6.36 降至 4.90）。

§6 渐进式编码与压缩解释

6.1 率失真分析

将变分下界的各项视为信息论量：

- **率（Rate）**：$L_1 + \cdots + L_T$，用于描述”不可察觉的细节”的编码长度。
- **失真（Distortion）**：L_0，对应最终重建质量。

CIFAR10 最佳模型：率 $= 1.78$ bits/dim，失真 $= 1.97$ bits/dim（约等于 RMSE $= 0.95$，基于 $[0, 255]$ 尺度）。**超过一半的无损码长用于编码人眼不可辨别的细节**，体现了扩散模型天然的有损压缩归纳偏置。

6.2 渐进式生成

在反向过程采样中，随着步数增加：

- **大尺度特征（低频结构）先出现**：整体形状、姿态、颜色调性。
- **细节纹理（高频细节）后出现**：毛发、纹理、精细边缘。

这与感知压缩的顺序完全一致，支持”扩散模型是一种渐进式压缩器”的论断。

6.3 与自回归解码的联系

通过对变分下界式 (8) 的等价重写，可以证明：

- 若将扩散过程长度设为数据维度 D，且每步正向过程恰好遮盖一个坐标，则扩散模型退化为**标准自回归模型**。
- 高斯扩散模型因此可视为具有**广义比特顺序**的自回归模型，其中噪声的全局混合方式无法被任何坐标重排所复现。
- 扩散步数 $T = 1000$ 远小于图像维度（$32 \times 32 \times 3 = 3072$），说明扩散模型可以在更短的”解码序列”中完成生成。

§7 潜空间插值

利用正向过程 q 作为随机编码器，对两张源图像 $\mathbf{x}_0, \mathbf{x}'_0$ 进行加噪：$\mathbf{x}_t, \mathbf{x}'_t \sim q(\cdot|\mathbf{x}_0)$，然后在潜空间线性插值 $\bar{\mathbf{x}}_t = (1-\lambda)\mathbf{x}_t + \lambda\mathbf{x}'_t$，再通过反向过程解码 $\bar{\mathbf{x}}_0 \sim p(\mathbf{x}_0|\bar{\mathbf{x}}_t)$。

- 插值效果**平滑变化**姿态、肤色、发型、表情等语义属性。
- 更大的 t 对应更粗粒度（语义级）的插值；$t = 0$ 退化为像素空间线性混合；$t = 1000$ 时源图像信息完全丢失，输出为全新样本。

§8 总结与思考

8.1 核心贡献回顾

DDPM 的四大核心贡献

1. **高质量图像生成：**首次证明扩散概率模型可以生成媲美 GAN 的高质量样本（CIFAR10 FID 3.17），打破了”扩散模型不能生成好样本”的固有认知。
2. **理论等价性揭示：**建立了扩散模型（变分推断）、去噪分数匹配和退火 Langevin 动力学之间深刻的数学等价性，统一了三个研究方向。
3. **简化训练目标：**推导出 L_{simple}——一个形式极其简洁（纯粹的 MSE 损失）、效果显著优于理论下界的训练目标，为后续工作奠定了基础。
4. **压缩理论联系：**将扩散模型的采样过程解释为渐进式有损解压缩，并建立了与自回归解码的形式化联系。

8.2 局限性

注意

- **采样速度慢：**每次生成需要运行 $T = 1000$ 步网络前向传播，单批 128 张 256×256 图像需要约 300 秒。相比 GAN（一步前向）慢 2-3 个数量级。这促使了后续 DDIM、DPM-Solver 等加速采样方法的诞生。
- **负对数似然不竞争：**尽管样本质量高，模型的精确似然不如自回归模型（如 Sparse Transformer）。原因是大量码长被”浪费”在编码不可感知的细节上。
- **仅无条件生成：**本文未探讨条件生成（文本引导、类别引导等），这在后续 GLIDE、DALL-E 2、Stable Diffusion 等工作中被大幅拓展。

8.3 后续工作展望

DDPM 作为扩散模型的奠基工作，直接催生了一大批重要后续研究：

- **加速采样：**DDIM（Song et al., 2020）通过非马尔可夫过程将步数减至 50 步；DPM-Solver 进一步加速至 10-20 步。
- **条件生成：**Classifier Guidance（Dhariwal & Nichol, 2021）和 Classifier-free Guidance 使扩散模型支持文本/类别条件控制。
- **潜空间扩散：**LDM/Stable Diffusion（Rombach et al., 2022）将扩散过程移至 VAE 的低维潜空间，大幅降低计算成本。
- **架构改进：**DiT（Peebles & Xie, 2023）用纯 Transformer 替换 U-Net，在大规模上效果更优。

- **视频生成**：Video Diffusion Models 将 DDPM 推广到时序数据（Sora 等的理论基础）。

核心摘要

DDPM 以其**优雅的数学推导、简洁的训练目标和惊艳的生成质量**，成为了现代生成 AI 浪潮中最重要的基础工作之一。其揭示的" 噪声预测 ≡ 分数匹配 ≡ Langevin 采样" 三位一体框架，至今仍是理解扩散模型的核心理论支柱。

§9 个人理解与思考

扩散模型如何从"破坏"中学习"创造"？

1. **学习逆转一个固定的破坏过程**：前向过程是一个固定的、无参数的马尔科夫链。逐步向一张干净的图像添加高斯噪声；反向过程模型需要一个参数化的马尔科夫链 p_θ, 这个过程是信息被逐步重建。
2. **DDPM 独特之处**：它巧妙地设计了一个固定、简单、可解析计算的前向过程，将复杂的生成问题转化为学习逆转这个随机过程。这就使得模型训练稳定、目标明确。

为什么要预测噪声而非预测图像？

1. **最直接的思路**：最直接的方式是让模型去预测前向过程的后验均值。这个后验均值是最佳的去噪目标。
2. **巧妙的重新参数化**：通过一个简单的变量替换，与其让模型预测一个复杂的均值，不如就让模型去预测当初被添加到 x_0 上的那个原始噪声 ϵ
3. **精妙之处**：简化了学习目标，比预测一个复杂数据相关的均值简单得多。DDPM 的训练目标和去噪分数匹配的目标完全等价。采样过程本质上就是在执行退火朗之万动力学，用学习到的"得分"来指导从噪声到数据的逐步演变。

什么是"渐进解码"

1. **数学本质**：论文将变分下界 L 重新解释为一个渐进的有损压缩编码。发送方通过扩散过程逐步向图像添加噪声，接收方通过反向过程逐步去噪。
2. **生成过程揭示的信息层次**：早期几乎是纯噪声，此时的 x_0 也是模糊一片，但是已经能勾勒出图像最为宏观的结构。比如物体的整体轮廓、颜色基调、

大致的布局；到了中期，随着去噪的进行，x_0 开始出现更清晰的形状，物体的类别特征开始逐渐显现；晚期模型专注于填充精细的纹理、边缘、小部件。