Latent Diffusion Models (LDM) 论文阅读笔记

High-Resolution Image Synthesis with Latent Diffusion Models

Robin Rombach, Andreas Blattmann, Dominik Lorenz, Patrick Esser, Björn Ommer CVPR 2022

阅读笔记整理

2026 年 3 月 1 日

§1 论文基本信息与速览

发表会议	CVPR 2022
作者单位	Ludwig Maximilian University of Munich & IWR, Heidelberg University; Runway ML
关键词	扩散模型 (Diffusion Models)、潜在空间 (Latent Space)、文本到图像生成 (Text-to-Image)、交叉注意力 (Cross-Attention)、高效生成 (Efficient Generation)
开源代码	`https://github.com/CompVis/latent-diffusion`

核心摘要

本文提出了 **潜在扩散模型 (Latent Diffusion Models, LDM)**，其核心思想是将扩散过程从高维像素空间转移到预训练自编码器的低维潜在空间。这样做不仅大幅降低了训练和推理的计算成本，还通过引入交叉注意力机制实现了灵活的多模态条件控制。LDM 在图像修补、超分辨率、文本到图像生成等任务上达到了当时最先进的性能，并为后续的 Stable Diffusion 奠定了技术基础。

通过将扩散模型放在一个感知上等效但计算上更紧凑的潜在空间中训练，LDM 实现了高质量、高效率、高灵活性的图像合成。

§2 研究背景与动机

2.1 核心问题：扩散模型的计算瓶颈

扩散模型（Diffusion Models, DMs）在图像生成领域表现出色，但直接在像素空间操作存在严重缺陷：

- **训练成本极高**：强大的 DM 需要数百 GPU 天（如 ADM 需 150–1000 V100 天），导致高昂的碳足迹，限制了其普及。
- **推理速度慢**：生成一张图像需要数十至上千步的顺序计算，延迟高。
- **计算资源浪费**：像素空间中包含大量人眼难以察觉的高频细节，但模型仍需对每个像素进行梯度计算，造成不必要的开销。

已有生成模型的优缺点

- **GANs**：生成速度快，但训练不稳定、易模式崩溃，难以覆盖复杂分布。
- **自回归模型 (AR)**：生成质量高，但参数量巨大（数十亿），计算成本高。
- **像素扩散模型 (Pixel DMs)**：质量最优，但计算负担过重，无法被广泛使用。

2.2 核心洞察：感知压缩与语义压缩的分离

作者观察到，DM 的学习过程可分解为两个阶段（见图 2 原文）：1. **感知压缩 (Perceptual Compression)**：去除高频细节，保留语义信息。2. **语义压缩 (Semantic Compression)**：学习数据的组成结构。

因此，一个自然的想法是：先训练一个自编码器，将图像压缩到一个感知上等价但维度更低的潜在空间，然后在该空间上训练扩散模型。这样扩散模型只需关注语义结构，而高频细节由自编码器处理，从而大幅提升效率。

§3 扩散模型预备知识

给定数据样本 x_0，定义前向过程 q 逐步添加噪声：

$$q(x_t|x_0) = \mathcal{N}(x_t; \alpha_t x_0, \sigma_t^2 I), \quad t = 1, \ldots, T$$

其中 α_t, σ_t 控制信噪比 $\mathrm{SNR}(t) = \alpha_t^2/\sigma_t^2$，通常设计为单调递减。

生成模型 $p_\theta(x_0)$ 通过逆过程 $p_\theta(x_{t-1}|x_t)$ 逐步去噪，通常参数化为高斯分布：

$$p_\theta(x_{t-1}|x_t) = \mathcal{N}(x_{t-1}; \mu_\theta(x_t, t), \tilde{\beta}_t I)$$

训练目标通常简化为去噪得分匹配：

$$L_{\mathrm{DM}} = \mathbb{E}_{x_0, \epsilon \sim \mathcal{N}(0,1), t} \left[\|\epsilon - \epsilon_\theta(x_t, t)\|^2 \right]$$

其中 $x_t = \alpha_t x_0 + \sigma_t \epsilon$，$\epsilon_\theta$ 为预测噪声的网络。

§4 方法详解

LDM 的整体架构分为三个关键模块：感知压缩模型、潜在扩散模型、条件控制机制。

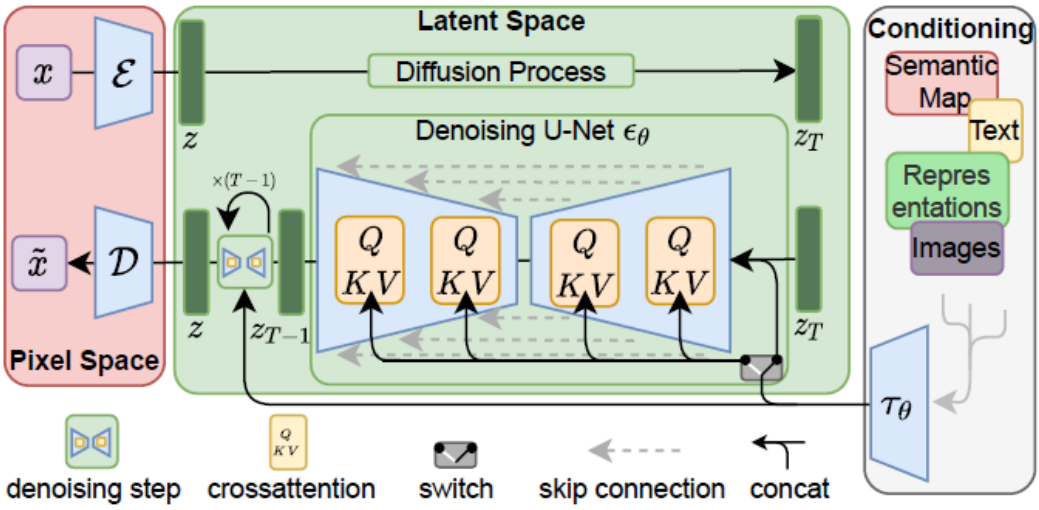

图 1: LDM 整体架构

4.1 感知压缩模型 (Perceptual Compression Model)

目标：学习一个能够将图像 $x \in \mathbb{R}^{H\times W\times 3}$ 压缩到低维潜在空间 $z \in \mathbb{R}^{h\times w\times c}$ 的自编码器 $(\mathcal{E}, \mathcal{D})$，同时保证解码后 $\tilde{x} = \mathcal{D}(z)$ 与原始图像在感知上无异。

- **下采样因子** $f = H/h$，论文考察了 $f \in \{1, 2, 4, 8, 16, 32\}$。
- **训练目标**：结合感知损失 (LPIPS) 和对抗训练 (PatchGAN)，避免仅用 L1/L2 损失导致的模糊。
- **正则化**：为避免潜在空间尺度任意，引入两种正则化：
  - **KL-正则化**：对潜在表示施加轻微的 KL 散度惩罚，类似 VAE。
  - **VQ-正则化**：在解码器内部引入向量量化层，类似 VQGAN。
- **关键优势**：由于后续的扩散模型是卷积的，可以利用潜在空间的 2D 结构，因此可以使用相对温和的压缩率（如 $f = 4$ 或 8），保留更多细节。

4.2 潜在扩散模型 (Latent Diffusion Model)

目标：在固定好的潜在空间 $z = \mathcal{E}(x)$ 上训练一个扩散模型，学习分布 $p(z)$。

$$L_{\text{LDM}} = \mathbb{E}_{\mathcal{E}(x),\epsilon\sim\mathcal{N}(0,1),t}\left[\|\epsilon - \epsilon_\theta(z_t, t)\|^2\right]$$

其中 z_t 是 z 经过 t 步前向加噪后的结果，ϵ_θ 为时间条件 UNet。

由于 z 的维度远小于像素空间，训练和采样都变得高效。生成时，只需从噪声 z_T 开始反向去噪得到 z_0，再通过解码器 $\mathcal{D}$ 一步得到最终图像。

4.3 条件控制机制 (Conditioning via Cross-Attention)

为了让 LDM 支持文本、语义图等多种条件输入，作者设计了通用的交叉注意力融合机制。

- 引入一个领域特定的编码器 τ_θ（如文本任务中用 Transformer），将条件 y 映射为中间表示 $\tau_\theta(y) \in \mathbb{R}^{M \times d_\tau}$。
- 在 UNet 的每一层中，将 $\tau_\theta(y)$ 通过交叉注意力层注入：

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d}}\right) V$$

其中 $Q = W_Q^{(i)} \phi_i(z_t)$ 来自 UNet 中间特征，$K, V = W_K^{(i)} \tau_\theta(y), W_V^{(i)} \tau_\theta(y)$。

$$L_{\text{LDM}} = \mathbb{E}_{\mathcal{E}(x), y, \epsilon \sim \mathcal{N}(0,1), t} \left[\|\epsilon - \epsilon_\theta(z_t, t, \tau_\theta(y))\|^2 \right]$$

τ_θ 与 ϵ_θ 联合优化。

这种设计使得 LDM 能够无缝处理文本、类别标签、语义分割图、低分辨率图像等多种条件，且无需为每个任务修改架构。

4.4 压缩权衡与最优选择

论文通过实验（图 6、图 7）系统研究了不同下采样因子 f 的影响：

- $f = 1$（像素空间）：训练缓慢，效率最低。
- $f = 32$：压缩过强，信息损失严重，生成质量受限。
- $f = 4$ 或 8：在效率和保真度之间取得最佳平衡，是 LDM 的首选。

注意

信号-噪声比 (SNR) 的影响：对于 KL-正则化的潜在空间，方差可能较大，导致 SNR 偏高，模型在去噪早期过早分配细节。适当缩放潜在空间（除以标准差）可以降低 SNR，改善生成质量，尤其适用于卷积式采样生成超分辨率图像。

§5 实验与结果

5.1 实验设置

- **数据集：** CelebA-HQ, FFHQ, LSUN-Churches/Bedrooms（无条件生成）；ImageNet（类别条件）；LAION-400M, MS-COCO（文本到图像）；Places（修补）；ImageNet（超分辨率）。
- **评估指标：** FID、Inception Score (IS)、Precision/Recall、PSNR、SSIM、LPIPS、用户研究。
- **基线模型：** 对比了 StyleGAN, ADM, VQGAN, SR3, LaMa 等。

5.2 关键实验结果

任务	LDM 结果	对比 SOTA
CelebA-HQ 256^2 (FID↓)	5.11	LSGM (7.22), StyleGAN (4.16 但 Recall 低)
FFHQ 256^2 (FID↓)	4.98	StyleGAN (4.16 但 Recall 高)
LSUN-Bedrooms 256^2 (FID↓)	2.95	ADM (1.9)
ImageNet 256^2 类别条件 (FID↓)	3.60	ADM-G (4.59)
MS-COCO 文本到图像 (FID↓)	12.63 (引导后)	GLIDE (12.24), Make-A-Scene (11.84)
ImageNet 4× 超分辨率 (FID↓)	2.8	SR3 (5.2)
Places 修补 (FID↓)	1.50	LaMa (2.21)

- **效率大幅提升：** LDM 相比像素扩散模型，训练速度提升至少 2.7 倍，采样速度也显著加快。
- **质量不降反升：** 在多数任务上，LDM 的 FID 等指标优于或媲美当时的 SOTA，证明了潜在空间扩散的有效性。
- **条件灵活性：** 交叉注意力机制使 LDM 能无缝支持多种条件输入，无需任务特定架构修改。
- **数据规模效应：** 在超大规模数据集（LAION）上，LDM 能够学习到丰富的语义，生成高度逼真的图像。

§6 讨论与扩展

6.1 模型行为的可视化分析

- **潜在空间的结构**：VQ-正则化的潜在空间方差接近 1，具有较好的 SNR，训练更稳定；KL-正则化的空间可能需要重新缩放。
- **卷积式采样 (Convolutional Sampling)**：LDM 可以生成超过训练分辨率的图像（如从 256^2 生成 1024^2），通过在更大尺寸的潜在空间上进行滑动窗口式前向传播实现，体现了模型对空间结构的泛化能力。
- **注意力距离**：自注意力层使模型在早期就能关注全局信息，类似 CNN 的感受野，但更灵活。

6.2 局限性

- **采样速度仍慢于 GAN**：虽然比像素扩散快，但迭代采样依然比 GAN 的单次前向传播慢。
- **对第一阶段的依赖**：最终生成质量受限于自编码器的重建能力，对于需要像素级精度的任务（如医学图像）可能成为瓶颈。
- **可解释性与控制性**：潜在空间中的每个维度缺乏明确语义，精细控制生成内容仍具挑战。
- **社会影响**：生成模型可能被用于制造虚假信息（deepfakes），也可能泄露训练数据中的隐私信息。

6.3 未来方向

- 探索更高效的采样器（如 DPM-Solver、LCM）以进一步加速推理。
- 更强大的条件融合架构（如 Diffusion Transformer, DiT）。
- 潜在空间的可解释性研究，实现更精细的控制。
- 将 LDM 扩展到视频、3D、音频等其他模态。

§7 总结

核心技术贡献

1. **潜在空间扩散：**首次将扩散模型从像素空间迁移到预训练自编码器的低维潜在空间，极大降低了计算成本，成为 Stable Diffusion 的技术基石。
2. **交叉注意力条件机制：**提出通用条件注入方法，使扩散模型能够灵活利用文本、语义图等多种模态信息，为多模态生成开辟了道路。
3. **效率与质量兼得：**通过温和的压缩（$f = 4, 8$），在保持高保真重建的同时显著提升训练和推理效率，使扩散模型得以“民主化”。

注意

对后续工作的启发：LDM 的成功启发了大量后续工作，包括 Stable Diffusion、DALL • E 2、Imagen 等，推动了生成式 AI 的爆发式发展。其“先压缩再生成”的范式也被广泛应用于视频、音频、3D 生成领域。

§8 个人思考与总结

LDM 的核心洞察

1. **分离压缩阶段：**扩散模型的学习过程可以分解为两个阶段：感知压缩和语义/概念压缩。感知压缩过程去除高频细节和保留语义信息，语义/概念压缩过程学习数据的组成和结构。
2. **引入预训练的自编码器：**自编码器负责感知压缩，它将图像压缩到一个低维的”潜在空间”。这个过程去除了像素级的高频噪声和细节，保留了关键的感知结构。通过实验发现，使用一个温和的压缩率，可以在保证高质量重建的同时，大幅降低数据维度。而扩散模型负责的是语义压缩。扩散模型只需要在紧凑的潜在空间上学习数据的分布。

为什么 LDM 找到了黄金平衡点？

1. **f=1（像素空间）：**虽然理论上可以直接在像素空间训练扩散模型，但计算成本极高，训练时间长，且效率低下。
2. **f=32（过度压缩）**：图片被压缩了 1024 倍，但是压缩过程本身造成了不可

逆的信息丢失。

3. **f=4 或 8（黄金平衡）**：效率足够高并且保真度足够好。