NeRF 论文精读笔记

NeRF: Representing Scenes as Neural Radiance Fields for View Synthesis

Mildenhall, Srinivasan, Tancik et al. ECCV 2020

阅读笔记整理

2026 年 2 月 28 日

§1 论文基本信息

发表会议	ECCV 2020（European Conference on Computer Vision）
作者单位	UC Berkeley、Google Research、UC San Diego
关键词	新视角合成、体积渲染、隐式神经表示、MLP
代码	`https://www.matthewtancik.com/nerf`

核心摘要

本文提出 **NeRF**（Neural Radiance Field，神经辐射场），用一个简单的多层感知机（MLP）隐式表示三维场景，并通过**可微体积渲染**从已知视角图像优化网络权重，最终实现对任意新视角的高质量合成。这是第一个能从自然拍摄的 RGB 图像中渲染出逼真新视角的连续神经场景表示方法。

§2 研究背景与动机

2.1 问题定义：新视角合成 (Novel View Synthesis)

给定一组已知相机位姿的场景图像，目标是合成从**任意新视角**观察该场景的图像。

核心挑战

- 如何在**稀疏输入视角**条件下恢复场景的完整几何与外观？
- 如何处理复杂的**非朗伯反射** (Non-Lambertian)效果（镜面高光等）？
- 如何在不使用离散体素网格的前提下高效存储场景？

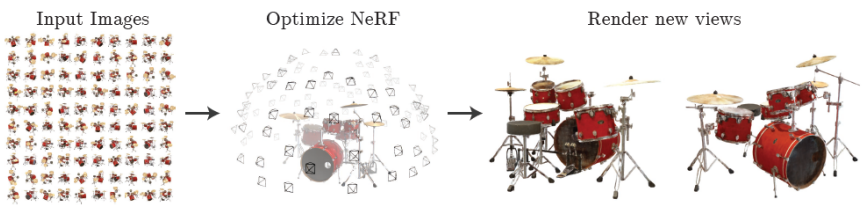

图 1: 新视角合成示例：输入为左侧的几张图像，目标是生成右侧的任意新视角图像。

2.2 现有方法局限性

方法类别	代表工作	主要缺陷
网格渲染	可微光栅化器	梯度优化困难，需初始化模板网格
体素网格	Neural Volumes	分辨率受限，存储代价高
神经隐式表面	SRN	几何过平滑，无法表示复杂细节
光场融合	LLFF	大视角变化时几何估计失败

2.3 NeRF 的核心思路

用 MLP 的权重本身作为场景存储介质——无需离散化，场景以连续函数形式隐式编码在网络参数中，通过**体积渲染** (Volume Rendering)将三维信息投影为二维图像，利用渲染误差端到端优化。

§3 方法详解

3.1 场景表示：5D 神经辐射场 *(Neural Radiance Field)*

核心输入输出

NeRF 将场景建模为一个 **5D 连续函数**：

$$F_\Theta : (\underbrace{\mathbf{x}}_{3D\text{位置}}, \underbrace{\mathbf{d}}_{2D\text{视向}}) \longrightarrow (\underbrace{\mathbf{c}}_{\text{RGB 颜色}}, \underbrace{\sigma}_{\text{体密度}})$$

- $\mathbf{x} = (x, y, z)$：空间位置坐标
- $\mathbf{d} = (\theta, \phi)$：相机观察方向（单位向量）
- $\mathbf{c} = (r, g, b)$：该位置沿视向发出的辐射颜色
- σ：**体密度** (Volume Density)，表示射线在此处终止的微分概率

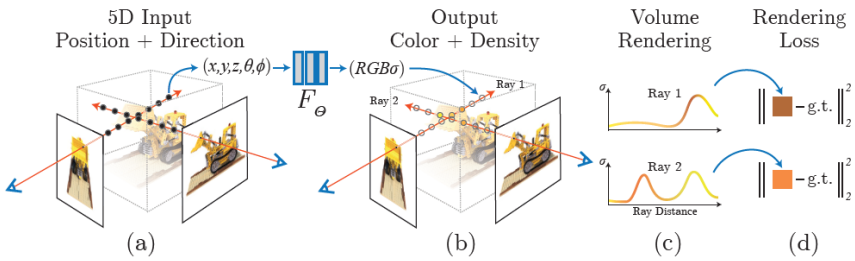

图 2: 新视角合成示例：输入为左侧的几张图像，目标是生成右侧的任意新视角图像。

3.1.1 多视角一致性 *(Multi-view Consistency)* 设计

为保证场景表示的物理合理性：

- **体密度** σ 仅依赖位置 $\mathbf{x}$，与视角无关（几何应独立于观察方向）
- **颜色** $\mathbf{c}$ 同时依赖位置 $\mathbf{x}$ 和视向 $\mathbf{d}$，从而建模视角相关的高光效果

3.1.2 网络结构 *(Network Architecture)*

阶段	描述
输入层	位置编码后的 $\gamma(\mathbf{x})$（60 维）
主干网络	8 层全连接，每层 256 通道，ReLU 激活；第 5 层有 skip connection
输出（第一阶段）	体密度 σ（ReLU）+ 256 维特征向量
方向融合	拼接视向编码 $\gamma(\mathbf{d})$（24 维），再经 1 层 128 通道 FC
输出（第二阶段）	RGB 颜色（Sigmoid 激活）

3.2 体积渲染 *(Volume Rendering)*

相机射线 $\mathbf{r}(t) = \mathbf{o} + t\mathbf{d}$ 穿越场景，其期望颜色为：

$$C(\mathbf{r}) = \int_{t_n}^{t_f} T(t)\,\sigma(\mathbf{r}(t))\,\mathbf{c}(\mathbf{r}(t), \mathbf{d})\,dt \tag{1}$$

其中**累积透射率** (Accumulated Transmittance)：

$$T(t) = \exp\left(-\int_{t_n}^{t} \sigma(\mathbf{r}(s))\,ds\right) \tag{2}$$

$T(t)$ 表示射线从 t_n 传播到 t 而不被遮挡的概率。

3.2.1 离散近似 *(Discrete Approximation)*

实际计算时，采用**分层采样** (Stratified Sampling)：将 $[t_n, t_f]$ 均分为 N 个区间，每区间内均匀随机采一点：

$$t_i \sim \mathcal{U}\left[t_n + \frac{i-1}{N}(t_f - t_n),\ t_n + \frac{i}{N}(t_f - t_n)\right]$$

离散渲染公式（alpha 合成形式）：

$$\hat{C}(\mathbf{r}) = \sum_{i=1}^{N} T_i\,(1 - e^{-\sigma_i \delta_i})\,\mathbf{c}_i, \quad T_i = \exp\left(-\sum_{j=1}^{i-1} \sigma_j \delta_j\right) \tag{3}$$

其中 $\delta_i = t_{i+1} - t_i$ 为相邻采样点间距，$\alpha_i = 1 - e^{-\sigma_i \delta_i}$ 等价于传统 Alpha 值。

- 全程**可微**，可直接使用梯度下降端到端优化
- 无需显式表面，自然处理透明与半透明物体
- 避免离散体素网格的分辨率瓶颈

3.3 位置编码 *(Positional Encoding)*

注意

直接使用原始 (x, y, z, θ, ϕ) 坐标输入 MLP，网络倾向于学习低频函数（频谱偏置），导致渲染结果过度平滑，无法还原高频细节（纹理、边缘、高光）。

3.3.1 编码函数

将标量 p 映射到 $2L$ 维向量：

$$\gamma(p) = \big(\sin(2^0\pi p),\ \cos(2^0\pi p),\ \ldots,\ \sin(2^{L-1}\pi p),\ \cos(2^{L-1}\pi p)\big) \tag{4}$$

输入	频率层数 L	编码维度
位置 $\mathbf{x}$	10	$3 \times 2 \times 10 = 60$
视向 $\mathbf{d}$	4	$3 \times 2 \times 4 = 24$

将连续输入映射到高维频率空间，使 MLP 能够**拟合高频函数**，从而精确还原几何细节与材质纹理。这一思路与 Transformer 中的位置编码同名但目的不同：此处是为了让网络表示高频空间变化，而非表达序列顺序。

3.4 层级体积采样 *(Hierarchical Volume Sampling)*

3.4.1 动机

在空旷空间和遮挡区域均匀采样效率低下——这些区域对最终渲染几乎无贡献，却消耗大量计算。

3.4.2 双网络方案

同时训练**粗网络**（Coarse Network）和**细网络**（Fine Network）：

1. **粗采样**：在射线上均匀采 $N_c = 64$ 个点，输入粗网络，得到粗渲染颜色：

$$\hat{C}_c(\mathbf{r}) = \sum_{i=1}^{N_c} w_i\,\mathbf{c}_i, \quad w_i = T_i(1 - e^{-\sigma_i\delta_i})$$

2. **重要性采样**：将权重 w_i 归一化为分段常数 PDF，从该分布中再采 $N_f = 128$ 个点（集中在有内容的区域）

3. **细采样**：将两次采样点（$N_c + N_f = 192$ 点）合并，输入细网络，得最终渲染结果 $\hat{C}_f(\mathbf{r})$

将采样算力**集中在场景内容丰富的区域**，减少对空白区域的浪费，在相同计算量下提升渲染质量。

3.5 训练与损失函数 (*Training & Loss*)

对每个 batch 中的射线集合 $\mathcal{R}$，同时最小化粗/细网络的渲染误差：

$$\mathcal{L} = \sum_{\mathbf{r}\in\mathcal{R}} \left[\|\hat{C}_c(\mathbf{r}) - C(\mathbf{r})\|_2^2 + \|\hat{C}_f(\mathbf{r}) - C(\mathbf{r})\|_2^2 \right] \tag{5}$$

超参数	值
Batch 大小	4096 条射线
优化器	Adam，$\beta_1 = 0.9$，$\beta_2 = 0.999$，$\epsilon = 10^{-7}$
学习率	$5 \times 10^{-4} \to 5 \times 10^{-5}$（指数衰减）
训练轮数	100k–300k 次迭代（约 1–2 天，单张 V100）
相机参数	合成数据用 GT 位姿；真实数据用 COLMAP 估计

§4 实验与结果

4.1 数据集

- **Diffuse Synthetic 360°**（DeepVoxels 数据集）：4 个朗伯体，简单几何，479 训练 / 1000 测试，512×512
- **Realistic Synthetic 360°**（自建数据集）：8 个路径追踪渲染的复杂物体，100 训练 / 200 测试，800×800
- **Real Forward-Facing**（真实场景）：8 个手持手机拍摄的前向场景，20–62 张输入，1008×756

注意

在 Real Forward-Facing 数据集上，LLFF 的 LPIPS 指标略优于 NeRF（0.212 *vs.* 0.250）。但作者指出 NeRF 在多视角一致性和伪影数量方面均优于 LLFF，建议结合补充视频综合评估。

4.2 存储效率对比

方法	存储开销	说明
LLFF	$> 15\,\mathrm{GB}$	每张输入图像对应一个 3D 体素网格
NeRF	$\approx 5\,\mathrm{MB}$	仅网络权重，**压缩比约 3000×**

4.3 消融实验 *(Ablation Study)*

在 Realistic Synthetic 数据集上的消融结果（PSNR，越高越好）：

编号	配置	PSNR↑	SSIM↑	LPIPS↓
1	无位置编码、无视角依赖、无层级采样	26.67	0.906	0.136
2	无位置编码 *(No Positional Encoding)*	28.77	0.924	0.108
3	无视角依赖 *(No View Dependence)*	27.66	0.925	0.117
4	无层级采样 *(No Hierarchical)*	30.06	0.938	0.109
5	仅 25 张输入图像	27.78	0.925	0.107
6	仅 50 张输入图像	29.79	0.940	0.096
7	位置编码频率 $L = 5$	30.59	0.944	0.088
8	位置编码频率 $L = 15$	30.81	0.946	0.096
9	**完整模型**（$L = 10$，100 张图）	**31.01**	**0.947**	**0.081**

- **位置编码贡献最大**：去掉后 PSNR 下降约 2.2 dB
- **视角依赖其次**：去掉后难以建模高光等非朗伯效果（PSNR 下降 3.35 dB）
- 层级采样进一步提升效果（+0.95 dB），并显著提升采样效率
- 即使只用 25 张输入图像，NeRF 仍优于所有使用 100 张图像的对比方法

§5 技术贡献总结

三大核心贡献

1. **连续 5D 神经辐射场表示**
   首次将复杂场景建模为连续函数，用 MLP 权重隐式存储，克服了离散表示的分辨率瓶颈。
2. **可微体积渲染流程**
   基于经典体积渲染理论，结合层级采样策略，构建端到端可微的渲染管线，仅需 RGB 图像与相机位姿即可优化。
3. **位置编码提升高频表示能力**
   将输入坐标映射至高频空间，突破神经网络的频谱偏置，成功复现高频几何与纹理细节。

§6 方法局限性与未来方向

已识别的局限性

- **训练速度慢：** 单场景需 1–2 天，每帧渲染约 30 秒（V100）
- **场景独立性：** 每个场景需单独训练，无法泛化到新场景
- **静态场景假设：** 无法处理动态物体或光照变化
- **可解释性差：** 网络权重不像体素或网格那样直观可分析
- **需要精确相机位姿：** 真实数据依赖 COLMAP 估计，对极端情况不稳定

后续研究方向（部分重要扩展工作）

- **加速：** Instant-NGP（哈希编码）、TensoRF（张量分解），将训练压缩到分钟级
- **动态场景：** D-NeRF、HyperNeRF 等引入时间维度
- **泛化：** pixelNeRF、GRF 等实现跨场景少样本合成
- **可编辑性：** EditNeRF、CLIP-NeRF 支持语义编辑
- **无位姿输入：** BARF、NeRF–（NeRF minus minus）联合优化位姿与场景

§7 关键公式速查

名称	公式
连续渲染积分	$C(\mathbf{r}) = \int_{t_n}^{t_f} T(t)\,\sigma(\mathbf{r}(t))\,\mathbf{c}(\mathbf{r}(t), \mathbf{d})\,dt$
累积透射率	$T(t) = \exp\left(-\int_{t_n}^{t} \sigma(\mathbf{r}(s))\,ds\right)$
离散渲染	$\hat{C}(\mathbf{r}) = \sum_{i=1}^{N} T_i(1 - e^{-\sigma_i \delta_i})\mathbf{c}_i$
Alpha 值	$\alpha_i = 1 - e^{-\sigma_i \delta_i}$
位置编码	$\gamma(p) = (\sin 2^0\pi p, \cos 2^0\pi p, \ldots, \sin 2^{L-1}\pi p, \cos 2^{L-1}\pi p)$
层级权重	$w_i = T_i(1 - e^{-\sigma_i \delta_i})$，归一化得 PDF
损失函数	$\mathcal{L} = \sum_{\mathbf{r}} \left(\lVert \hat{C}_c - C \rVert_2^2 + \lVert \hat{C}_f - C \rVert_2^2\right)$

§8 个人理解与思考

为什么 NeRF 如此有影响力？

- **方法创新性强：** NeRF 开创了连续的神经场景表示的新范式。NeRF 提出了一个紧凑的多层感知机 (MLP) 来对一个连续的 5D 辐射场的函数进行了表示。这种方法能够从任意连续的坐标点去查询得到颜色和密度，从而就能够实现无限分辨率的场景表示。
- **效果显著：** 在多个数据集上大幅超越传统方法，生成的图像质量和多视角一致性均达到很高的水平。
- **启发后续研究：** 引发了大量关于加速、动态场景、泛化能力等方面的后续工作，成为计算机视觉和计算机图形学领域的研究热点。
- **核心组件的设计十分巧妙：** 采用了位置编码、分层体素采样、可微分的体渲染。整个从 5D 辐射场到 2D 图像的渲染过程完全可微，所以说这个模型仅仅需要一组已知的相机位姿的二维图像作为监督信号，通过最小化渲染

图像和真实图片的误差，从而来优化 MLP 的参数。这样就根本不需要任何的三维的几何真值。

为什么 NeRF 要选择用 MLP 来记忆一个场景？

- **传统方法：**传统方法的流程是先通过多视图几何算出显式的几何，然后再贴上纹理。而 NeRF 完全跳过了显式几何重建的这一步。
- **端到端的函数拟合：**NeRF 不关心几何是什么的这个中间问题，只关心最终的结果。把整个场景看作一个 5D 输入到 4D 输出（RGB+ 密度）的一个映射函数。把场景的重建问题就转化为了函数的优化问题。
- **MLP 的表达：**MLP 类似一个极为高效的压缩器，将数十/百张 2D 图像里包含的 3D 信息，压缩到一个几兆字节的网络权重里。这个网络权重本身就隐式地编码了场景的几何和纹理信息。合成新视角的时候，只需要内插在训练时候从不同视角记忆下来的光场信息。
- **摆脱对高质量几何的依赖：**NeRF 通过体积密度这个“软”的表示，绕过了硬性的表面判断，而是用连续密度值来表示“这里有多大可能有物体”。这就让优化过程变得非常平滑，从错误中就能够逐渐修正，而非像 MVS 那样陷入局部最优。

NeRF 的位置编码和 Transformer 中的位置编码有什么区别？

- **离散序列 vs. 连续函数：**Transformer 中的位置编码是为了给离散的序列元素（如单词）提供位置信息，而 NeRF 的位置编码是为了将连续的空间坐标映射到高维频率空间，以增强 MLP 对高频细节的拟合能力。
- **作用机制不同：**Transformer 通常使用可以学习的嵌入向量，或者固定的 sin/cos 函数，将位置信息添加到 token 的词嵌入上，是一种加法式的特征注入。NeRF 将输入的低维坐标通过一组不同频率的 sin/cos 函数映射到一个高维的空间，相当于从时域转到了频域，这样 MLP 就可以更容易地学习到高频变化的函数。
- **位置编码的重要性：**如果没有位置编码，那么 MLP 就会被迫用自己的非线性层去生成高频的细节，这对于网络是十分困难的，由于频谱偏置，学习过程会非常缓慢并且效果很差。位置编码就相当于一个预处理器，让 MLP 去组合一组现成的、已知频率的基函数。这大大降低了优化的难度，是的网络能够在可接受时间范围内收敛到高精度的结果。

NeRF 的核心局限性

- **渲染效率低：**要得到一条光线的颜色，就需要先沿着它密集采样，然后对每一个采样点都前向传播一次 MLP。计算量大，且计算模式不友好。它是大量的、连续的、小矩阵乘法，难以充分利用 GPU 的并行能力。
- **无法建模空和实：**由于 MLP 必须同时为空间中的每一个点预测密度和颜色，所以这就意味着即使在没有任何物体的空旷区域，MLP 也必须计算出一个接近于 0 的密度值。这就会导致大量的计算被浪费在了“空”上。分层采样虽然缓解了这个问题，但是无法根除。
- **动态和可编辑性缺失：**场景信息被锁死在 MLP 的数百万个权重中，是高度耦合的。如果想移动场景中的一个物体，相当于要在整个 MLP 的高维参数空间中找到一个对应的变化，这几乎是不可能的。所以说难以进行场景编辑、组合和物理的模拟。
- **训练时间长：**生成、优化场景时间长。
- **总结：**NeRF 的局限源自于其“隐式连续”的本质。为了获得连续性，它牺牲了显式的可控性和渲染的效率。这也是后续 3DGS 看重的痛点，从而采取显式、离散的高斯作为基元。

笔记整理自原论文：Mildenhall B, Srinivasan PP, Tancik M, et al. *NeRF: Representing Scenes as Neural Radiance Fields for View Synthesis.* ECCV, 2020. `arXiv:2003.08934`