SAM 论文阅读笔记

Segment Anything

Alexander Kirillov, Eric Mintun, Nikhila Ravi, et al. ICCV 2023

阅读笔记整理

2026 年 3 月 1 日

§1 论文基本信息

发表会议	ICCV 2023（最佳论文提名）
作者单位	Meta AI Research, FAIR
关键词	基础模型（Foundation Model）、可提示分割（Promptable Segmentation）、数据引擎（Data Engine）、大规模数据集（SA-1B）、零样本迁移（Zero-shot Transfer）
开源代码	`https://github.com/facebookresearch/segment-anything`
数据集	SA-1B：11M 图像，1.1B 掩码

核心摘要

本文提出了 **Segment Anything 项目**，首次构建了用于图像分割的 **基础模型（SAM）**。通过定义 **可提示分割任务**（给定任意点、框、文本等提示输出有效掩码），设计 **SAM 模型**（图像编码器 + 提示编码器 + 轻量解码器，支持多掩码输出处理歧义），并构建 **数据引擎**迭代生成迄今为止最大的分割数据集 **SA-1B**（11M 图像，1.1B 掩码）。SAM 在零样本迁移到 23 个下游分割任务时表现卓越，性能常与全监督方法相当甚至更优。

§2 研究背景与动机

2.1 核心问题

在 NLP 领域，大规模预训练语言模型（如 GPT）通过提示工程实现强大的零样本/少样本泛化。而在计算机视觉中，图像分割缺乏类似的大规模、自然可获取的数据源（掩码不像文本那样广泛存在），且现有模型多是任务特定（task-specific），难以灵活适应新任务。

构建分割基础模型的挑战

- **任务定义**：如何设计一个统一的预训练目标，使得模型能够泛化到各种未见过的分割任务？
- **模型架构**：如何设计一个既能支持灵活提示输入，又能实时交互（摊销实时性）的模型？
- **数据规模**：分割掩码无法像文本那样从互联网大规模获取，如何构建足够大规模、多样化的数据集？

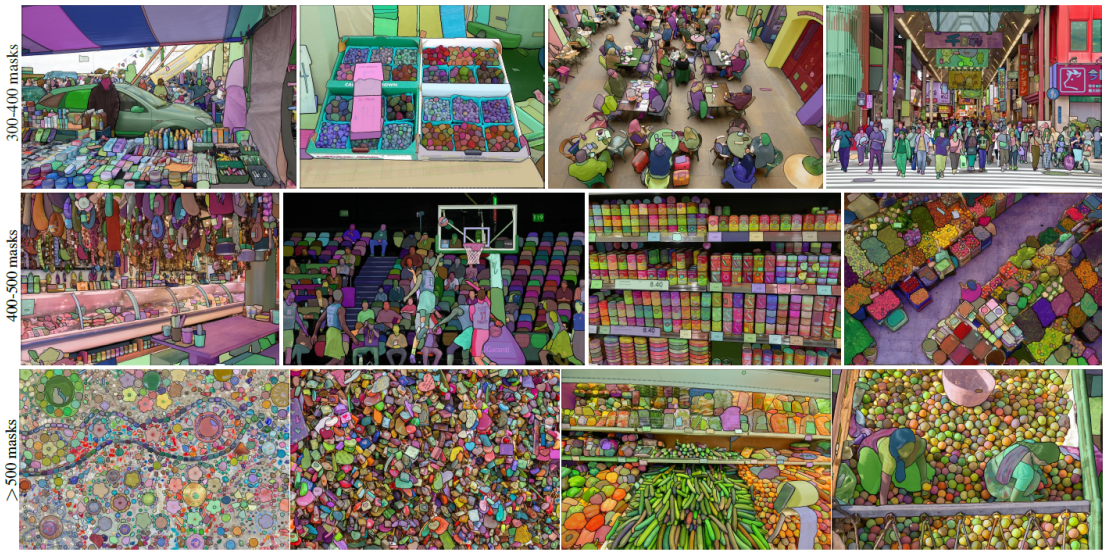

2.2 SAM 的核心思路

受 NLP 提示工程的启发，作者将“提示”概念引入分割，要求模型对任意提示输出有效掩码。通过解耦图像编码和提示处理，实现实时交互。并通过“数据引擎”循环迭代，让模型辅助数据标注，再用新数据改进模型，最终生成超大规模数据集。

§3 方法详解

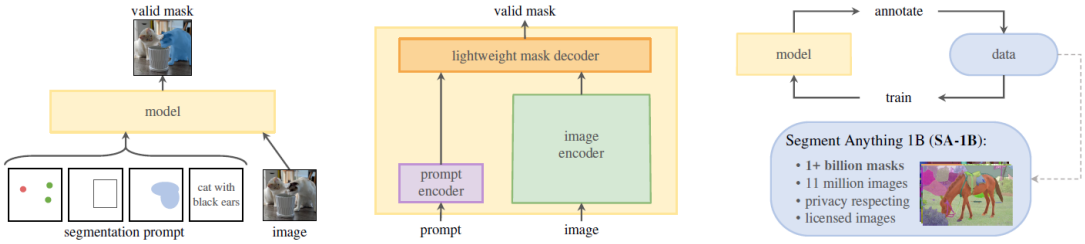

(a) **Task**: promptable segmentation (b) **Model**: Segment Anything Model (**SAM**) (c) **Data**: data engine (top) & dataset (bottom)

3.1 模型架构 *(SAM Architecture)*

SAM 由三个核心组件构成：图像编码器、提示编码器、轻量级掩码解码器。

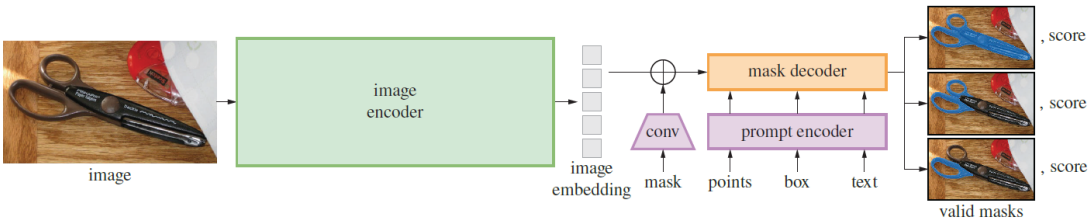

$$\mathbf{f} = \text{ImageEncoder}(\mathbf{I}) \in \mathbb{R}^{H\times W\times C} \tag{1}$$

$$\mathbf{p} = \text{PromptEncoder}(\text{prompt}) \tag{2}$$

$$\mathbf{m} = \text{MaskDecoder}(\mathbf{f}, \mathbf{p}) \in \mathbb{R}^{H\times W\times 3} \quad \text{(3 masks for ambiguity)} \tag{3}$$

其中：

- **I**：输入图像（缩放至 1024×1024）。
- **f**：图像嵌入，由 MAE 预训练的 ViT 编码器输出（16× 下采样，64×64）。
- PromptEncoder：处理稀疏提示（点、框、文本）和稠密提示（掩码），输出提示嵌入。
- **m**：预测的掩码，SAM 默认输出 3 个掩码以处理歧义。

SAM 核心处理流程

1. **图像编码**：输入图像通过 **ViT-H/16**（MAE 预训练）得到 64×64 的图像嵌入，该嵌入可被后续所有提示复用。
2. **提示编码**：
   - **稀疏提示**：点、框用位置编码 + 类型嵌入表示；文本用 CLIP 文本编码器嵌入。
   - **稠密提示**：输入掩码通过卷积下采样后与图像嵌入逐元素相加。
3. **掩码解码**：
   - 图像嵌入和提示嵌入输入到 **两层的 Transformer 解码器块**，交替进行自注意力和交叉注意力，更新所有嵌入。
   - 最后通过 **动态分类器**（由输出 token 经 MLP 生成的卷积核）与上采样的图像嵌入逐点积，得到每个像素的前景概率。
4. **歧义处理**：对于单点等歧义提示，预测 3 个掩码（对应整体、部分、子部分），训练时只回传最小损失；同时预测 IoU 分数用于排序。

3.2 数据引擎 *(Data Engine)*

数据引擎三阶段

1. **人工辅助阶段**：专业标注员使用 SAM 交互式标注（点/框），模型实时辅助。共收集 4.3M 掩码（120k 图像）。
2. **半自动阶段**：先用检测器生成可信掩码预填图像，标注员补充剩余对象。共收集 5.9M 额外掩码（180k 图像）。
3. **全自动阶段**：用改进的 SAM（多掩码输出 + 稳定性过滤）在 11M 图像上自动生成 1.1B 高质量掩码，构成 SA-1B。

注意

歧义感知的自动标注：通过 32×32 点网格预测多掩码，结合 IoU 置信度、稳定性过滤（不同阈值下掩码 IoU>95

3.3 损失函数与训练

$$L = 20 \cdot L_{\text{focal}} + 1 \cdot L_{\text{dice}}$$

- L_{focal}：Focal Loss，处理类别不平衡，聚焦难分样本。
- L_{dice}：Dice Loss，衡量掩码重叠度，对形状敏感。
- 训练时模拟交互：每样本 11 轮迭代（初始提示 + 8 轮点采样 + 2 轮无新提示的自精炼）。

§4 实验与结果

4.1 数据集与设置

- **预训练**：SA-1B（11M 图像，1.1B 掩码）。
- **零样本评估**：23 个多样化分割数据集（涵盖航拍、水下、显微、X 光、驾驶、绘画等）。
- **下游任务**：边缘检测（BSDS500）、目标提议（LVIS v1）、实例分割（COCO/LVIS）、文本到掩码。
- **基线**：RITM（交互式分割）、ViTDet-H（全监督检测器）、HED（边缘检测）等。

4.2 与 SOTA 的对比

任务	指标	SAM	基线（全监督/SOTA）
单点分割（23 数据集平均）	mIoU	47.5	RITM: 43.2
单点分割（人类评分 1-10）	平均分	8.1	RITM: 5.6
边缘检测（BSDS500）	R50	0.928	HED: 0.923
目标提议（LVIS AR@1000）	AR	59.3	ViTDet-H: 63.0
实例分割（LVIS mask AP）	AP	46.5	ViTDet-H: 62.1
实例分割（人类评分）	平均分	8.1	ViTDet-H: 6.8

4.3 消融实验

- **数据引擎阶段**：每阶段加入后性能提升，仅用全自动数据与三阶段数据几乎持平 → 自动生成掩码质量足够高。
- **数据规模**：1M 图像（ 10% SA-1B）与全数据结果相当，100M 掩码可能是“甜点区间”。
- **模型规模**：ViT-H 优于 ViT-L，ViT-L 优于 ViT-B，但增益边际递减。

§5 内部表示检查 *(Probing the Latent Space)*

作者对 SAM 的潜在空间进行了初步探索：

- **掩码嵌入的语义相似性**：通过提取图像裁剪区域内与掩码对齐的图像嵌入，发现同一图像中，与查询掩码嵌入最相似的掩码往往在形状和语义上相关（即使 SAM 未经过语义监督）。
- **这表明 SAM 的表示可能对下游任务（如数据标注、特征提取）有潜在价值。**

注意

尽管 SAM 未显式学习语义，但其嵌入空间可能隐式捕捉了物体形状和部分语义信息，这为未来利用 SAM 进行开放词汇分割或特征迁移提供了可能。

§6 总结

核心技术贡献

1. **可提示分割任务**：将 NLP 的提示概念引入分割，定义了统一的预训练目标和零样本迁移接口。
2. **SAM 模型**：解耦图像编码和提示处理，实现摊销实时性；多掩码输出解决歧义问题。
3. **数据引擎 SA-1B**：通过模型-数据迭代闭环，构建了迄今为止最大、最多样化的分割数据集。
4. **零样本泛化能力**：展示了 SAM 在多种未见任务和域上的惊人表现，为视觉基础模型开辟了新路径。

SAM 与传统分割范式的对比

- **传统范式：**为每个任务训练专用模型（如实例分割、边缘检测），需大量标注数据。
- **SAM 范式：**一个模型通过提示工程适配所有任务，无需微调，且能泛化到新域。
- **关键突破：**从“任务特定”到“任务通用”，类似 NLP 中从 BERT 到 GPT 的演进。

§7 个人理解与思考

核心技术贡献

1. **可提示分割任务：**将 NLP 的提示概念引入分割，定义了统一的预训练目标和零样本迁移接口。
2. **SAM 模型：**解耦图像编码和提示处理，实现摊销实时性；多掩码输出解决歧义问题。
3. **数据引擎 SA-1B：**通过模型-数据迭代闭环，构建了迄今为止最大、最多样化的分割数据集。
4. **零样本泛化能力：**展示了 SAM 在多种未见任务和域上的惊人表现，为视觉基础模型开辟了新路径。

SAM 与传统分割范式的对比

- **传统范式：**为每个任务训练专用模型（如实例分割、边缘检测），需大量标注数据。
- **SAM 范式：**一个模型通过提示工程适配所有任务，无需微调，且能泛化到新域。
- **关键突破：**从“任务特定”到“任务通用”，类似 NLP 中从 BERT 到 GPT 的演进。

SAM 的“可提示分割”任务

1. **统一的预训练目标：**通过定义“给定任意提示输出有效掩码”的任务，SAM 能够在预训练阶段学习到适应各种提示的能力，从而实现零样本迁移。

2. **解决零样本迁移：**一旦模型被这样训练好，就像一个“分割通才”。下游的任何分割任务，只要能转化成一个“提示”问题，就能用 SAM 来解决。SAM 的目标是在任何提示下都能够生成有效掩码。

SAM 的模型架构解析

1. **解耦计算：**重型图像编码器：这是一个巨大的 Transformer(ViT-H)，负责将图像编码成一个高维的图像嵌入。轻量级提示编码器和掩码解码器：这两个模块负责处理输入的提示，并与图像嵌入交互，快速生成掩码。

2. **实现摊销实时：**最昂贵的图像编码部分只对每张图像执行一次。实时交互的提示处理和掩码生成部分非常轻量级，允许用户在交互式应用中快速得到反馈。