# ViT 论文阅读笔记

*An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale*

Alexey Dosovitskiy, Lucas Beyer, et al. ICLR 2021

阅读笔记整理

2026 年 2 月 28 日

## §1 论文基本信息

| | |
|---|---|
| 发表会议 | ICLR 2021 |
| 作者单位 | Google Research, Brain Team |
| 关键词 | 视觉大模型 (Vision Transformer)、自注意力机制 (Self-Attention)、图像分类 (Image Classification)、大规模预训练 (Large-scale Pre-training) |
| 开源代码 | `https://github.com/google-research/vision_transformer` |

**核心摘要**

本文提出了 **Vision Transformer (ViT)**，证明了在图像识别任务中，完全可以摆脱对卷积神经网络 (CNN) 的依赖。通过将图像分割成 16x16 的像素块（Patches），并直接将这些块的序列输入到标准的 Transformer 模型中，ViT 在经过大规模数据预训练后，能够取得媲美甚至超越当时 SOTA 卷积网络的卓越性能，同时大幅减少了训练所需的计算资源。

# §2 研究背景与动机

## 2.1 核心问题

在 NLP 领域，Transformer 已经成为首选模型，而在计算机视觉（CV）领域，卷积神经网络（ResNet 等）依然占据主导地位。

**传统 CV 结合 Attention 的局限**

- **复杂性**：之前的研究多是将 Attention 与 CNN 结合，或者用特殊设计的 Attention 模式完全替换卷积。
- **难以扩展**：这些特殊设计的 Attention 架构（如局部多头自注意力、稀疏注意力等）需要复杂的工程实现，难以在现代硬件加速器上高效扩展。
- **计算成本**：如果天真地将全局自注意力应用于图像的每一个像素，计算成本将与像素数量呈平方级增长，这对于真实分辨率的图像是不可缩放的。

## 2.2 ViT 的核心思路

受到 NLP 领域 Transformer 扩展成功的启发，作者尝试以尽可能少的修改，直接将标准 Transformer 应用于图像。

# §3 方法详解

## 3.1 模型架构 *(Model Architecture)*

ViT 的设计尽可能紧跟原始的 Transformer，以便能够开箱即用地利用可扩展的 NLP Transformer 架构及其高效实现。

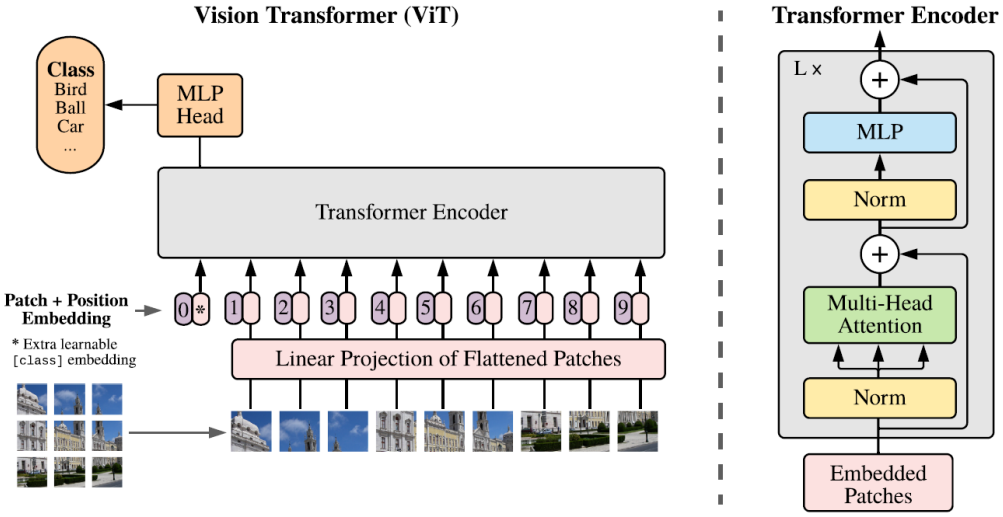


图 1: ViT 模型架构示意图

$$\mathbf{z}_0 = [\mathbf{x}_{class}; \mathbf{x}_p^1\mathbf{E}; \mathbf{x}_p^2\mathbf{E}; \ldots; \mathbf{x}_p^N\mathbf{E}] + \mathbf{E}_{pos} \tag{1}$$

$$\mathbf{z}'_\ell = MSA(LN(\mathbf{z}_{\ell-1})) + \mathbf{z}_{\ell-1} \tag{2}$$

$$\mathbf{z}_\ell = MLP(LN(\mathbf{z}'_\ell)) + \mathbf{z}'_\ell \tag{3}$$

$$\mathbf{y} = LN(\mathbf{z}_L^0) \tag{4}$$

其中：

- $\mathbf{z}_0$：Transformer 编码器的输入嵌入序列。
- $\mathbf{x}_{class}$：可学习的分类标记（Class Token），用于聚合全局信息。
- $\mathbf{x}_p^i\mathbf{E}$：第 $i$ 个图像块（Patch）通过线性投影矩阵 $\mathbf{E} \in \mathbb{R}^{(P^2 \cdot C) \times D}$ 得到的嵌入向量。
- $\mathbf{E}_{pos}$：可学习的一维位置编码，用于保留图像块的空间位置信息。
- $MSA(\cdot)$：多头自注意力（Multi-Head Self-Attention）操作。
- $LN(\cdot)$：层归一化（Layer Normalization）。
- $MLP(\cdot)$：多层感知机（通常包含两个全连接层与 GELU 激活函数）。
- $\mathbf{z}'_\ell$：第 $\ell$ 层自注意力模块的输出（包含残差连接）。
- $\mathbf{z}_\ell$：第 $\ell$ 层 MLP 模块的输出（包含残差连接）。

- $\mathbf{y}$：最终图像表示，即分类标记 $\mathbf{z}_L^0$ 经过层归一化后的输出。
- $L$：Transformer 编码器的总层数。

**ViT 核心处理流程**

1. **图像分块 (Patching)**：将输入图像 $\mathbf{x} \in \mathbb{R}^{H \times W \times C}$ 划分为固定大小的二维块，并将每个块展平为向量，得到序列 $\mathbf{x}_p \in \mathbb{R}^{N \times (P^2 \cdot C)}$，其中 $P$ 为块大小，$N = HW/P^2$ 为块的数量（即 Transformer 的输入序列长度）。
2. **线性投影 (Linear Projection)**：通过可训练矩阵 $\mathbf{E} \in \mathbb{R}^{(P^2 \cdot C) \times D}$ 将每个展平块映射到 $D$ 维嵌入空间，生成 *patch embeddings*：$\mathbf{x}_p^i \mathbf{E}$（$i = 1, \ldots, N$）。
3. **添加 Class Token**：在序列开头引入一个可学习的分类标记 $\mathbf{x}_{\text{class}} \in \mathbb{R}^D$（记作 $z_0^0$），使其与所有 patch embeddings 一同参与后续计算；最终该标记的输出 $z_L^0$ 经归一化后作为整张图像的表示 $\mathbf{y}$。
4. **位置编码 (Positional Embedding)**：加入可学习的一维位置编码 $\mathbf{E}_{\text{pos}} \in \mathbb{R}^{(N+1) \times D}$，与上述拼接后的序列逐元素相加，为模型提供块间的空间顺序信息。
5. **Transformer 编码器堆叠**：将得到的序列 $\mathbf{z}_0$ 送入 $L$ 层 Transformer 编码器。每一层 $\ell$ 依次包含：
   - **多头自注意力 (MSA)**：先进行层归一化 (LN)，再通过 MSA 聚合全局信息，并通过残差连接将输入加回：$\mathbf{z}'_\ell = \text{MSA}(\text{LN}(\mathbf{z}_{\ell-1})) + \mathbf{z}_{\ell-1}$。
   - **多层感知机 (MLP)**：再次层归一化后，经 MLP 进行非线性变换，并添加残差连接：$\mathbf{z}_\ell = \text{MLP}(\text{LN}(\mathbf{z}'_\ell)) + \mathbf{z}'_\ell$。

   经过 $L$ 层后，取分类标记对应的输出 $\mathbf{z}_L^0$，最后通过层归一化得到图像表示 $\mathbf{y} = \text{LN}(\mathbf{z}_L^0)$，供分类头使用。

## 3.2 归纳偏置与微调策略 *(Inductive Bias & Fine-Tuning)*

**ViT 与 CNN 的归纳偏置对比**

- **CNN**：局部性 (Locality)、二维邻域结构和空间平移等变性 (Translation Equivariance) 被硬编码到了每一层中。
- **ViT**：图像特有的归纳偏置大大减少。只有 MLP 层是局部的和平移等变的，自注意力层是全局的。所有的空间关系都必须从头开始学习。

**注意**

**高分辨率微调 (Fine-tuning at Higher Resolution)**
通常在较高分辨率下进行微调有助于提升性能。当输入更高分辨率的图像时，保持 Patch Size 不变，从而产生更长的序列。此时预训练的位置编码不再匹配，需要根据其在原图像中的几何位置对预训练位置编码进行 **2D 插值 (2D Interpolation)**。这是 ViT 中唯一一次手动注入关于 2D 结构的归纳偏置。

# §4 实验与结果

## 4.1 数据集与设置

预训练数据集包括：ImageNet (1.3M)、ImageNet-21k (14M) 和未公开的巨大数据集 JFT-300M (303M)。下游迁移评估包括：ImageNet、CIFAR-10/100、Oxford-IIIT Pets、Oxford Flowers-102 以及 VTAB 测试套件。

## 4.2 与 SOTA 的对比

| 数据集 | ViT-H/14 (JFT) | ViT-L/16 (JFT) | BiT-L (ResNet) | Noisy Student |
|---|---|---|---|---|
| ImageNet | **88.55%** | 87.76% | 87.54% | 88.4% |
| CIFAR-100 | **94.55%** | 93.90% | 93.51% | - |
| VTAB (19 tasks) | **77.63%** | 76.28% | 76.29% | - |
| **训练算力开销** | **2.5k TPU-days** | **0.68k TPU-days** | 9.9k TPU-days | 12.3k TPU-days |

- **全面超越**：在 JFT-300M 上预训练的 ViT-H/14 和 ViT-L/16 性能在所有基准数据集上均超越了以往的 SOTA CNN（如 BiT-L）。
- **更低算力要求**：达到 SOTA 的同时，ViT 所消耗的预训练计算资源大大减少（如 ViT-H/14 仅用时 BiT-L 的四分之一）。

## 4.3 数据规模的作用 *(Pre-training Data Requirements)*

ViT 对预训练数据量极其敏感。

- 当在较小的数据集（ImageNet, 1.3M）上预训练时，ViT-Large 的表现甚至不如基础的 ViT-Base。

- 在缺乏像 CNN 那样的归纳偏置时，小数据集会导致 ViT 严重过拟合。
- 只有在 JFT-300M 这样的超大规模数据集上，大型 Transformer 模型的全部优势才得以显现（大规模训练战胜了归纳偏置）。

## §5 内部表示检查 *(Inspecting Vision Transformer)*

通过可视化分析，作者探究了 ViT 如何处理图像：

- **Patch 嵌入的基函数**：第一层的线性投影学习到了类似于表示图像块精细结构的低维基函数（类似 PCA 主成分）。
- **位置编码自动学习 2D 拓扑**：模型通过位置编码的余弦相似度学会了编码图像内部的距离，同一行/列的块拥有相似的嵌入，完美重建了图像的 2D 网格拓扑。
- **注意力距离 (Attention Distance)**：类似于 CNN 中的感受野，自注意力机制使得模型即使在最底部的几层也能聚合跨越整个图像的全局信息。

## §6 总结

**核心技术贡献**

1. **直接且纯粹的迁移**：不引入额外图像特定归纳偏置，直接将 NLP 中标准的 Transformer 应用于图像 Patch 序列。
2. **规模效应的证明**：验证了虽然 Transformer 在小规模数据上由于缺乏归纳偏置表现欠佳，但在进行超大规模预训练后，可扩展性能够轻松弥补甚至超越归纳偏置的局限性。
3. **算力效率突破**：在性能优于 SOTA CNN 的同时，显著降低了达到同等性能所需的预训练计算开销。

# §7 个人理解与思考

**核心技术贡献**

1. **直接且纯粹的迁移：**不引入额外图像特定归纳偏置，直接将 NLP 中标准的 Transformer 应用于图像 Patch 序列。
2. **规模效应的证明：**验证了虽然 Transformer 在小规模数据上由于缺乏归纳偏置表现欠佳，但在进行超大规模预训练后，可扩展性能够轻松弥补甚至超越归纳偏置的局限性。
3. **算力效率突破：**在性能优于 SOTA CNN 的同时，显著降低了达到同等性能所需的预训练计算开销。